ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

**Программа подготовки бакалавров по направлению
Компьютерные науки и технологии**

Пестов Лев Евгеньевич

КУРСОВАЯ РАБОТА

Разработка системы семантической сегментации дорожной сцены с акцентом на сегментацию слабоконтрастных объектов

Научный руководитель
преподаватель НИУ ВШЭ - НН

Сенников Андрей Олегович

Нижний Новгород, 2026г.

Структура работы

1 Введение **5**

2 Теоретические основы семантической сегментации и доменной устойчивости **7**

2.1 Семантическая сегментация дорожной сцены 7

2.1.1 Формализация задачи pixel-wise классификации 7

2.1.2 Основные метрики: mIoU, class-wise IoU, Pixel Accuracy . . 8

2.2 Архитектурные подходы 10

2.2.1 CNN-подходы (DeepLabV3+ как классический baseline) . . 10

2.2.2 Transformer-подходы (SegFormer) 10

2.2.3 CNN-based foundation backbones (InternImage) 10

2.2.4 *Foundation*-бэкбоны в сегментации (DINOv2) 11

2.3 Domain Shift: DG, UDA, FDA — термины и различия 11

2.3.1 DG (Domain Generalization): обучение без target-домена . . 11

2.3.2 UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target 12

2.3.3 FDA (Fourier Domain Adaptation): частотная техника адаптации 12

2.3.4 Почему в данной работе основной протокол — source-only / DG-style 12

2.4 Обзор литературы и SOTA-контекст 12

2.4.1 Лидерборд Cityscapes→ACDC: что показывают UDA-методы 12

2.4.2 Какие идеи можно перенести в DG-постановку 13

2.4.3 Ограничения сопоставления DG-результатов с UDA-рейтинговыми результатами 13

3 Данные и экспериментальный протокол **13**

3.1 Описание датасетов 13

3.1.1 Cityscapes: структура, классы, разметка 13

3.1.2 ACDC: adverse-условия (fog/night/rain/snow), назначение в работе 13

3.2 Протокол экспериментов 14

3.2.1 Обучение на Cityscapes 14

3.2.2 Оценка на ACDC (без обучения на ACDC в основной линии) 14

3.2.3 Риски и ограничения протокола 14

3.3 Метрики и критерии сравнения 14

3.3.1 Overall mIoU и per-condition mIoU 14

3.3.2 Class-wise IoU с акцентом на трудные/слабоконтрастные классы 15

4 Реализация системы и базовый пайплайн **15**

4.1 Технический стек и инфраструктура 15

4.1.1 PyTorch / PyTorch Lightning / Albumentations 15

4.1.2 Логирование экспериментов в ClearML 15

4.2 Базовый пайплайн обучения и оценки 15

4.2.1 Подготовка данных и аугментации baseline 15

4.2.2 Конфигурации обучения и выбор checkpoint 16

4.2.3 Скрипт/ноутбук оценки на ACDC 16

4.3 Исследуемые модели 16

4.3.1 DINOv2-Small (fine-tuning) 16

4.3.2 SegFormer-B2 16

4.3.3 Роль дополнительных baseline-моделей (DeepLabV3+, InternImage) как контекст 16

5 Базовые результаты и их анализ **17**

5.1 Результаты baseline на Cityscapes 17

5.1.1 Сравнение моделей по валидационным метрикам 17

5.2 Cross-domain результаты на ACDC 17

5.2.1 Overall и per-condition сравнение (fog/night/rain/snow) . . 17

5.2.2 Качественный анализ ошибок и типовых провалов 18

5.3 Выводы из baseline-этапа 18

5.3.1 Почему в основную линию берутся DINOv2 и SegFormer-B2 18

5.3.2 Что baseline не решает в low-contrast сценариях 18

6 План методических улучшений **19**

6.1 Экспериментальная шкала E0–E4 (накопительный протокол) . . . 19

6.1.1 E0: baseline 19

6.1.2 E1: low-contrast/weather augmentations 19

6.1.3 E2: class-balanced/focal 19

6.1.4 E3: frequency randomization (FDA-style идея без target) . . 19

6.1.5 E4: consistency regularization (weak/strong) на source 19

6.2 Две линии моделей в едином протоколе 20

6.2.1 DINOv2: ожидаемые эффекты и риски 20

6.2.2 SegFormer-B2: ожидаемые эффекты и риски 20

6.3 Отдельный подпункт о UDA (опционально) 20

6.3.1 Что такое UDA и как возможно обучение на неразмеченном ACDC 20

6.3.2 Почему UDA вынесен в дополнительный блок, а не в основной протокол 20

7 Заключение **20**

7.1 Итоги по текущему этапу 20
7.2 Что выполнено и что планируется завершить 21
7.3 Практические рекомендации и дальнейшая работа 21

8 Приложения **21**
8.1 Детальные таблицы метрик 21
8.2 Дополнительные визуализации предсказаний 21
8.3 Конфигурации экспериментов и параметры запусков 21

Список использованной литературы **22**

1. Введение

Актуальность темы. Развитие систем автономного вождения и помощи водителю (ADAS) требует высокой надежности алгоритмов компьютерного зрения в любых условиях эксплуатации. Современные методы семантической сегментации демонстрируют высокие показатели качества (mIoU $> 80\%$) на стандартных бенчмарках, таких как Cityscapes, содержащих изображения, полученные в благоприятных погодных условиях и при хорошем освещении. Однако реальная дорожная обстановка часто сопряжена с факторами, снижающими визуальное качество сцены: туман, дождь, снегопад, сумерки или ночное время суток. В таких условиях контрастность объектов критически снижается, что приводит к значительной деградации качества работы нейронных сетей, обученных на «чистых» данных.

Особую опасность представляет потеря детектирования слабоконтрастных объектов — пешеходов в темной одежде, велосипедистов или удаленных транспортных средств, сливающихся с фоном. Ошибка сегментации в таких случаях может привести к аварийным ситуациям. При этом сбор и разметка масштабных датасетов для всех возможных погодных условий является трудоемкой и дорогостоящей задачей. В связи с этим актуальной становится задача разработки методов адаптации моделей, обученных на качественных данных, к сложным условиям видимости без необходимости полной переразметки данных.

Проблема исследования заключается в существенном падении точности (Domain Shift) современных алгоритмов семантической сегментации при переходе от домена с хорошей видимостью к домену с неблагоприятными погодными условиями, особенно в части распознавания малых и слабоконтрастных объектов.

Цель работы — разработка и исследование методики повышения качества семантической сегментации дорожных сцен в сложных погодных условиях (туман, ночь, дождь) с использованием методов доменной адаптации и модификации процесса обучения.

Для достижения поставленной цели необходимо решить следующие **задачи**:

1. Провести обзор современных архитектур нейронных сетей (CNN и Transformer-based) для задачи семантической сегментации.

2. Изучить проблему доменного сдвига (Domain Shift) и методы повышения обобщающей способности моделей (Data Augmentation, Domain

Adaptation).

3. Реализовать базовый пайплайн обучения (baseline) на наборе данных Cityscapes и оценить его качество на данных со сложными погодными условиями (ACDC).

4. Разработать и внедрить модификации (аугментации, функции потерь), направленные на улучшение распознавания слабоконтрастных объектов.

5. Провести сравнительный анализ результатов и оценить эффективность предложенных методов.

Объект исследования: алгоритмы семантической сегментации изображений дорожных сцен.

Предмет исследования: методы повышения устойчивости нейронных сетей к изменению визуальных условий (освещение, погода) и снижению контраста.

2. Теоретические основы семантической сегментации и доменной устойчивости

2.1. Семантическая сегментация дорожной сцены

2.1.1. Формализация задачи pixel-wise классификации

Семантическая сегментация представляет собой задачу плотной (pixel-wise) классификации, в которой каждому пикселю входного изображения сопоставляется метка класса из заранее заданного множества. Формально, пусть задано входное изображение $X \in \mathbb{R}^{H \times W \times C}$, где H и W — пространственные размеры изображения (высота и ширина), а C — количество каналов (обычно $C = 3$ для RGB-изображений). Пусть $\mathcal{K} = \{1, 2, \ldots, K\}$ — множество целевых семантических классов, характерных для дорожной сцены (например, дорога, тротуар, здания, транспорт, пешеходы и т.д.).

Цель модели семантической сегментации (нейронной сети), параметризованной весами θ, заключается в поиске отображения f_θ:

$$f_\theta : \mathbb{R}^{H \times W \times C} \to \mathbb{R}^{H \times W \times K}, \tag{1}$$

которое преобразует входное изображение в тензор логитов $Z \in \mathbb{R}^{H \times W \times K}$. Для каждого пространственного положения (пикселя) с координатами (i, j) сеть предсказывает вектор $z_{i,j} \in \mathbb{R}^K$.

Вероятностное распределение принадлежности пикселя к каждому из K классов получается путем применения функции *softmax* вдоль канала классов:

$$p_{i,j}^{(k)} = \frac{\exp\left(z_{i,j}^{(k)}\right)}{\sum_{c=1}^{K} \exp\left(z_{i,j}^{(c)}\right)}, \tag{2}$$

где $p_{i,j}^{(k)}$ — предсказанная вероятность того, что пиксель (i, j) принадлежит классу k.

Итоговая предсказанная маска сегментации $\hat{Y} \in \mathcal{K}^{H \times W}$ формируется путем выбора класса с максимальной вероятностью для каждого пикселя:

$$\hat{y}_{i,j} = \arg\max_{k \in \mathcal{K}} p_{i,j}^{(k)}. \tag{3}$$

В процессе обучения модели наиболее распространенным функционалом потерь является средняя категориальная кросс-энтропия (Categorical Cross-

Entropy, CCE). Если $y_{i,j}$ — истинная метка класса для пикселя (i, j), представленная в виде one-hot вектора (где $y_{i,j}^{(k)} = 1$, если пиксель принадлежит классу k, и 0 иначе), то функция потерь имеет вид:

$$\mathcal{L}_{CE} = -\frac{1}{H \cdot W} \sum_{i=1}^{H} \sum_{j=1}^{W} \sum_{k=1}^{K} y_{i,j}^{(k)} \log \left(p_{i,j}^{(k)} \right). \tag{4}$$

В отличие от задач классификации изображений в целом или детектирования объектов, сегментация требует одновременно высокой семантической точности (понимания контекста сцены) и точной локализации пространственных границ объектов. Для задач автономного вождения особенно важна стабильность качества предсказаний: модель должна корректно выделять как крупные структуры (дорожное полотно, небо), так и мелкие, слабоконтрастные, но критически важные объекты (пешеходы вдали, дорожные знаки). Это делает задачу крайне чувствительной к доменному сдвигу (domain shift) между распределением данных, на которых модель обучалась (source domain), и распределением данных в реальных условиях применения (target domain), например, при изменении погодных условий или времени суток.

2.1.2. Основные метрики: mIoU, class-wise IoU, Pixel Accuracy

Для количественной оценки качества моделей семантической сегментации используются метрики, основанные на вычислении площадей перекрытия предсказанных и истинных масок. В основе вычислений лежат базовые элементы матрицы ошибок (Confusion Matrix), рассчитываемые независимо для каждого класса k:

- TP_k (True Positives) — количество истинно-положительных пикселей (пиксели, верно отнесенные к классу k);
- FP_k (False Positives) — количество ложно-положительных пикселей (пиксели, ошибочно отнесенные к классу k);
- FN_k (False Negatives) — количество ложно-отрицательных пикселей (пиксели класса k, отнесенные моделью к другому классу);
- TN_k (True Negatives) — количество истинно-отрицательных пикселей (пиксели других классов, корректно не отнесенные к классу k).

Ключевой метрикой качества в данной работе является **mIoU** (mean Intersection over Union — среднее пересечение над объединением). Сначала вычисляется метрика **class-wise IoU** для каждого отдельного класса k, которая определяется как отношение площади пересечения предсказанной маски и ground truth маски к площади их объединения:

$$\mathrm{IoU}_k = \frac{TP_k}{TP_k + FP_k + FN_k}. \tag{5}$$

Значение IoU_k строго лежит в диапазоне от 0 до 1. Анализ class-wise IoU позволяет проводить детальную диагностику поведения модели: например, выявлять классы с исторически низким качеством распознавания (такие как *bicycle*, *fence*, *pole* из-за их малой площади и сложной геометрии).

Интегральная метрика mIoU рассчитывается как арифметическое среднее значений IoU по всем K классам:

$$\mathrm{mIoU} = \frac{1}{K} \sum_{k=1}^{K} \mathrm{IoU}_k. \tag{6}$$

В отличие от простой пиксельной точности, mIoU является робастной метрикой в условиях сильного дисбаланса классов, который типичен для дорожных сцен (где класс «дорога» может занимать значительную часть изображения, а «светофор» — менее долей процента).

Дополнительно в работе используется базовая метрика **Pixel Accuracy (PA)** — доля корректно классифицированных пикселей по отношению к общему числу пикселей изображения:

$$\mathrm{PA} = \frac{\sum_{k=1}^{K} TP_k}{\sum_{k=1}^{K} (TP_k + FP_k + FN_k + TN_k)} = \frac{\sum_{i=1}^{H} \sum_{j=1}^{W} \mathbb{I}(\hat{y}_{i,j} = y_{i,j})}{H \cdot W}, \tag{7}$$

где $\mathbb{I}(\cdot)$ — индикаторная функция, равная 1 при выполнении условия и 0 в противном случае. Хотя PA легко интерпретируется, она может быть обманчиво высокой при доминировании фоновых классов, поэтому используется лишь в качестве вспомогательного индикатора.

Для оценки устойчивости моделей в *adverse*-условиях (неблагоприятных условиях видимости), отдельно агрегируются и анализируются метрики по специфическим подмножествам целевого датасета (например, сценарии *fog*, *night*, *rain*, *snow* в датасете ACDC). Это позволяет явно количественно оценить степень деградации сегментации для каждого типа погодного или оптического искажения.

2.2. Архитектурные подходы

2.2.1. CNN-подходы (DeepLabV3+ как классический baseline)

Сверточные архитектуры долгое время являлись основным стандартом для задачи семантической сегментации. В работе в качестве классического подхода рассматривается **DeepLabV3+ [1]**, сочетающая энкодер-декодерную схему, модуль *Atrous Spatial Pyramid Pooling* и *dilated* свертки для расширения эффективного рецептивного поля без потери разрешения признаков. Такой подход позволяет одновременно учитывать контекст на нескольких масштабах и уточнять границы объектов, что особенно важно для дорожных сцен с большим числом тонких структур и малых объектов. В оригинальной статье авторы сообщают о результате **82.1% mIoU** на тестовом наборе *Cityscapes* и **89.0% mIoU** на *PASCAL VOC 2012* без дополнительного post-processing. DeepLabV3+ в данной работе используется как понятный и интерпретируемый CNN-baseline для сравнения с более современными трансформерными и foundation-подходами.

2.2.2. Transformer-подходы (SegFormer)

SegFormer [2] относится к высокоэффективным трансформерным архитектурам для семантической сегментации. Особенностью архитектуры является использование иерархического энкодера, который выдает признаки на нескольких масштабах, не требуя при этом позиционного кодирования, и легкого MLP-декодера (многослойного персептрона). Декодер объединяет разномасштабные признаки для предсказания финальной маски, что обеспечивает хороший баланс между качеством сегментации и вычислительной сложностью. В оригинальной статье наиболее сильная конфигурация *SegFormer-B5* достигает **84.0% mIoU** на тестовом наборе *Cityscapes*, а вариант *SegFormer-B4* показывает **51.8% mIoU** на *ADE20K*. В данной работе используется конфигурация *SegFormer-B2* (реализованная через библиотеку `segmentation_models_pytorch`), которая представляет современный практический подход и выступает в качестве сильного трансформерного baseline, не являющегося foundation-моделью в строгом смысле.

2.2.3. CNN-based foundation backbones (InternImage)

InternImage [3] представляет собой CNN-based foundation-модель, в которой в качестве основного оператора используется *DCNv3* — деформируемая сверт-

ка, обеспечивающая большое эффективное рецептивное поле и адаптивное пространственное агрегирование признаков. Архитектура строится как иерархический четырехстадийный бэкбон, а ее блоки сочетают свойства современных CNN и transformer-подобный дизайн, включая *Layer Normalization*, *feed-forward network* и *GELU*. Благодаря этому InternImage рассматривается как важный промежуточный вариант между классическими сверточными сетями и крупными vision foundation models.

2.2.4. *Foundation*-бэкбоны в сегментации (DINOv2)

Foundation-подходы используют предварительное обучение на масштабных и разнообразных наборах изображений без разметки *(self-supervised learning)*, что существенно повышает переносимость признаков между различными доменами и задачами. **DINOv2 [4]** — современная архитектура на базе *Vision Transformer*, которая благодаря обучению с дистилляцией и специальным целевым функциям формирует богатые универсальные визуальные представления. В оригинальной статье показано, что даже замороженный бэкбон DINOv2 в связке с *ViT-Adapter* достигает **60.2% mIoU** на *ADE20K*, **86.9% mIoU** на *Cityscapes* и **89.0% mIoU** на *Pascal VOC*.

В рамках исследования модель **DINOv2-Small** рассматривается как основная для проверки гипотезы о том, что предобученные универсальные признаки повышают устойчивость сегментации в условиях пониженной видимости, низкого контраста и сложных погодных условий. Для решения задачи плотного предсказания (сегментации) поверх замороженного или дообучаемого (fine-tuning) бэкбона DINOv2 применяется специально разработанный легковесный линейный декодер (`LinearDecoder`). Он преобразует одномерную последовательность патч-токенов обратно в двумерное пространственное представление и с помощью билинейной интерполяции восстанавливает признаки до исходного разрешения изображения для попиксельной классификации.

2.3. Domain Shift: DG, UDA, FDA — термины и различия

2.3.1. DG (Domain Generalization): обучение без target-домена

Domain Generalization (DG) — это постановка, в которой модель обучается только на исходном домене (source), а затем тестируется на новом домене (target), недоступном в обучении. Для данной курсовой это означает обучение

на Cityscapes и оценку на ACDC без использования ACDC в тренировочном контуре.

2.3.2. UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target

Unsupervised Domain Adaptation (UDA) предполагает, что в процессе обучения доступны размеченные данные source-домена и неразмеченные данные target-домена. В этой постановке адаптация к target достигается через pseudo-labeling, consistency-регуляризацию, adversarial alignment и другие механизмы. Несмотря на высокую актуальность UDA в литературе по Cityscapes→ACDC, в основной части текущей работы UDA не является базовым протоколом.

2.3.3. FDA (Fourier Domain Adaptation): частотная техника адаптации

FDA (Fourier Domain Adaptation) — семейство методов, использующих преобразование в частотную область и модификацию низкочастотных компонент (стилевой информации) для уменьшения разрыва между доменами. В прикладном варианте идеи FDA могут использоваться и в DG-постановке в виде частотной рандомизации без прямого использования target-обучения.

2.3.4. Почему в данной работе основной протокол — source-only / DG-style

Основной протокол работы выбран как source-only transfer: обучение проводится на Cityscapes, а оценка выполняется на ACDC. Такой выбор делает постановку более строгой с точки зрения практической переносимости и соответствует задаче оценки устойчивости без дополнительного target-тюнинга. При этом подходы UDA рассматриваются как перспективное расширение и отдельное направление дальнейших экспериментов.

2.4. Обзор литературы и SOTA-контекст

2.4.1. Лидерборд Cityscapes→ACDC: что показывают UDA-методы

Современные лидерборды для протокола Cityscapes→ACDC в значительной степени доминируются UDA-методами. Это объясняется тем, что использование неразмеченных target-данных дает модели возможность частично адаптироваться к статистике adverse-условий еще до финального тестирования. В ре-

зультате абсолютные значения метрик UDA и DG/source-only, как правило, напрямую несопоставимы без учета различий протокола.

2.4.2. Какие идеи можно перенести в DG-постановку

Несмотря на различия протоколов, отдельные компоненты UDA-работ полезны и для DG: расширенные аугментации, частотные преобразования, балансировка вкладов классов, consistency-механизмы. В данной работе именно такие переносимые идеи используются в шкале методических улучшений E1–E4 поверх baseline.

2.4.3. Ограничения сопоставления DG-результатов с UDA-рейтинговыми результатами

При сравнении результатов необходимо явно фиксировать, использовались ли target-данные на этапе обучения. Для корректности выводов в курсовой работе сравнения с UDA-лидербордом трактуются как контекст состояния области, а не как прямое ранжирование относительно основного протокола исследования.

3. Данные и экспериментальный протокол

3.1. Описание датасетов

3.1.1. Cityscapes: структура, классы, разметка

Cityscapes является базовым source-датасетом для обучения. Он содержит городские сцены с плотной семантической разметкой и используется в работе для supervised-обучения моделей сегментации. Для экспериментов применяется стандартная схема обучения на 19 классах семантической разметки дорожной сцены.

3.1.2. ACDC: adverse-условия (fog/night/rain/snow), назначение в работе

ACDC (Adverse Conditions Dataset with Correspondences) используется в работе как целевой домен для оценки переносимости. Датасет включает сцены в неблагоприятных условиях видимости: туман, ночь, дождь и снег. В основном

протоколе ACDC применяется для валидационной оценки cross-domain качества без обучения на target-домене.

3.2. Протокол экспериментов

3.2.1. Обучение на Cityscapes

Обучение всех базовых моделей выполняется на Cityscapes в supervised-режиме. Для каждой модели фиксируются архитектура, конфигурация оптимизации, аугментации и критерий выбора лучшего checkpoint (по валидационной метрике качества).

3.2.2. Оценка на ACDC (без обучения на ACDC в основной линии)

После завершения обучения на Cityscapes модель оценивается на ACDC с раздельным анализом по adverse-подусловиям. Такой протокол позволяет измерить фактическую устойчивость к доменному сдвигу и определить, насколько модель сохраняет качество в условиях пониженного контраста и ухудшенной видимости.

3.2.3. Риски и ограничения протокола

Source-only протокол является строгим и практически полезным, однако может уступать UDA в абсолютных метриках. Дополнительно качество выводов зависит от полноты поклассового анализа и от того, насколько репрезентативны выбранные adverse-подусловия для целевой эксплуатационной среды.

3.3. Метрики и критерии сравнения

3.3.1. Overall mIoU и per-condition mIoU

В качестве основной агрегированной метрики используется overall mIoU. Для предметного анализа устойчивости отдельно рассчитываются per-condition метрики (fog/night/rain/snow), позволяющие выявлять режимы, в которых деградация качества наиболее заметна.

3.3.2. Class-wise IoU с акцентом на трудные/слабоконтрастные классы

Для соответствия цели исследования проводится поклассовый анализ IoU с акцентом на классы, чувствительные к ухудшению контраста и освещения. Такой анализ позволяет оценить не только среднее качество, но и практическую надежность системы в критичных сценариях.

4. Реализация системы и базовый пайплайн

4.1. Технический стек и инфраструктура

4.1.1. PyTorch / PyTorch Lightning / Albumentations

Экспериментальная система реализована на базе PyTorch, что обеспечивает гибкость проектирования модели и цикла обучения. PyTorch Lightning используется для структурирования тренировочного процесса и унификации этапов валидации и логирования. Для обработки изображений и аугментаций применяется Albumentations, позволяющая формировать воспроизводимые пайплайны преобразований.

4.1.2. Логирование экспериментов в ClearML

Для отслеживания и сопоставления запусков используется ClearML. В рамках каждого эксперимента фиксируются ключевые гиперпараметры, динамика метрик и артефакты оценивания. Это обеспечивает воспроизводимость сравнения baseline-моделей и последующих этапов E1–E4.

4.2. Базовый пайплайн обучения и оценки

4.2.1. Подготовка данных и аугментации baseline

Базовый пайплайн включает этапы загрузки данных, предобработки и применения стандартных аугментаций для training-режима. Для сравнения моделей используется унифицированная схема обработки данных, позволяющая минимизировать влияние неархитектурных факторов при анализе результатов.

4.2.2. Конфигурации обучения и выбор checkpoint

Для каждой модели фиксируется конфигурация оптимизатора, learning rate schedule, число эпох и размер входного изображения. Выбор итоговой версии модели осуществляется по лучшему checkpoint согласно валидационной метрике mIoU на source-валидации.

4.2.3. Скрипт/ноутбук оценки на ACDC

Cross-domain оценка реализована отдельными ноутбуками валидации на ACDC. Для каждой обученной модели вычисляются общие и поусловные метрики, а также формируются качественные визуализации предсказаний и типичных ошибок сегментации.

4.3. Исследуемые модели

4.3.1. DINOv2-Small (fine-tuning)

DINOv2-Small в режиме fine-tuning рассматривается как основная модель исследования благодаря сильным переносимым визуальным признакам и конкурентным результатам в baseline cross-domain оценке.

4.3.2. SegFormer-B2

SegFormer-B2 используется как вторая ключевая модель, обеспечивающая современный и вычислительно эффективный трансформерный baseline для сравнения с foundation-подходом.

4.3.3. Роль дополнительных baseline-моделей (DeepLabV3+, InternImage) как контекст

Дополнительные модели DeepLabV3+ и InternImage включены в обзор и сравнительный контекст baseline-этапа. Они позволяют расширить интерпретацию полученных результатов и обосновать выбор двух основных линий дальнейших экспериментов.

5. Базовые результаты и их анализ

5.1. Результаты baseline на Cityscapes

5.1.1. Сравнение моделей по валидационным метрикам

На этапе baseline выполнено обучение нескольких архитектур на Cityscapes с последующей внутренней валидацией. Сводные значения mIoU по доступным экспериментам приведены в таблице 1.

Таблица 1: Baseline-результаты на Cityscapes (validation)

Модель	**mIoU**
SegFormer-B2	0.7275
DeepLabV3+	0.6622
DINOv2-Small (fine-tuning)	0.6292
InternImage-Tiny	0.5510
DINOv2-Small (freeze backbone)	0.5273

По совокупности baseline-метрик и последующей cross-domain проверки для развития основной линии выбраны DINOv2-Small (fine-tuning) и SegFormer-B2.

5.2. Cross-domain результаты на ACDC

5.2.1. Overall и per-condition сравнение (fog/night/rain/snow)

Baseline-оценка на ACDC показала выраженную зависимость качества от типа adverse-условия. Сводные overall и per-condition метрики представлены в таблице 2.

Таблица 2: Baseline-результаты на ACDC (validation)

Модель	**Overall**	**Fog**	**Night**	**Rain**	**Snow**
DINOv2-Small	0.5436	0.6882	0.3349	0.5262	0.5816
SegFormer-B2	0.4462	0.5820	0.2461	0.4721	0.4553
InternImage-Tiny	0.3898	0.5379	0.2136	0.4307	0.3996
DeepLabV3+	0.3014	0.4421	0.1363	0.3293	0.3214

Полученные значения подтверждают два наблюдения. Во-первых, DINOv2-Small обеспечивает лучший overall mIoU среди рассмотренных baseline-моделей. Во-вторых, для всех моделей наиболее сложным поддоменом является night, что напрямую соответствует фокусу работы на слабоконтрастных объектах и обосновывает необходимость дальнейших улучшений E1–E4.

5.2.2. Качественный анализ ошибок и типовых провалов

Качественный анализ предсказаний показывает, что типичные ошибки связаны с границами объектов, малыми объектами и слиянием объектов с фоном при низкой видимости. Особенно критичны ошибки в классах, относящихся к уязвимым участникам движения и удаленным транспортным средствам. Эти наблюдения напрямую мотивируют дальнейшее усиление аугментаций и регуляризаций.

5.3. Выводы из baseline-этапа

5.3.1. Почему в основную линию берутся DINOv2 и SegFormer-B2

Выбор DINOv2-Small и SegFormer-B2 обусловлен сочетанием качества и исследовательской ценности: первая модель отражает потенциал foundation-предобучения, вторая обеспечивает сильный современный baseline без опоры на столь масштабный pretraining.

5.3.2. Что baseline не решает в low-contrast сценариях

Baseline-подход не обеспечивает достаточную устойчивость в наиболее сложных условиях low-contrast сцены, прежде всего в night-сценариях. Это определяет необходимость направленных модификаций тренировочного процесса и перехода к накопительной шкале улучшений.

6. План методических улучшений

6.1. Экспериментальная шкала E0–E4 (накопительный протокол)

6.1.1. E0: baseline

Этап E0 соответствует базовой конфигурации обучения без дополнительных механизмов domain-robustness, зафиксированной на этапе первичного сравнения моделей.

6.1.2. E1: low-contrast/weather augmentations

На этапе E1 в тренировочный контур добавляются аугментации, имитирующие ухудшение контраста, освещенности и погодные искажения. Цель — повысить устойчивость моделей к adverse-условиям без использования target-обучения.

6.1.3. E2: class-balanced/focal

Этап E2 вводит модификации функции потерь (class-balanced weighting и/или focal-компоненту), направленные на более устойчивое обучение по трудным и редким классам.

6.1.4. E3: frequency randomization (FDA-style идея без target)

На этапе E3 добавляется частотная рандомизация на основе идей FDA для снижения чувствительности моделей к стилевому доменному сдвигу. Важно, что реализация сохраняет DG-ограничение и не требует использования ACDC в обучении.

6.1.5. E4: consistency regularization (weak/strong) на source

Этап E4 включает consistency-регуляризацию между предсказаниями на weak/strong аугментациях одного и того же source-изображения, что должно повысить стабильность моделей к вариативности наблюдаемой сцены.

6.2. Две линии моделей в едином протоколе

6.2.1. DINOv2: ожидаемые эффекты и риски

Для DINOv2 ожидается наиболее высокий абсолютный уровень качества благодаря предобученным представлениям. Основной риск — ограниченный прирост от отдельных простых модификаций по сравнению с уже сильным baseline.

6.2.2. SegFormer-B2: ожидаемые эффекты и риски

Для SegFormer-B2 ожидается более заметный относительный эффект от аугментаций и регуляризаций. Риск состоит в том, что отдельные усиления могут быть чувствительны к настройке гиперпараметров и потребуют аккуратной абляции.

6.3. Отдельный подпункт о UDA (опционально)

6.3.1. Что такое UDA и как возможно обучение на неразмеченном ACDC

В дополнительном разделе может быть описан UDA-сценарий, в котором target-данные ACDC используются без разметки через pseudo-labeling и связанные механизмы регуляризации.

6.3.2. Почему UDA вынесен в дополнительный блок, а не в основной протокол

Основная часть исследования сохраняет source-only / DG-style постановку, поэтому UDA рассматривается как расширение и направление последующей работы, а не как базовый механизм достижения результатов текущей курсовой.

7. Заключение

7.1. Итоги по текущему этапу

В работе сформулирована и обоснована постановка повышения устойчивости семантической сегментации дорожной сцены в условиях пониженной видимости. Определен основной протокол исследования, включающий обучение на Cityscapes и cross-domain оценку на ACDC.

7.2. Что выполнено и что планируется завершить

На текущем этапе сформирован baseline-контур, выполнено первичное сравнение моделей и выделены две основные линии для дальнейшей абляции: DINOv2-Small и SegFormer-B2. Следующим шагом является последовательная реализация и количественная проверка этапов E1–E4.

7.3. Практические рекомендации и дальнейшая работа

Практическая ценность работы заключается в формировании воспроизводимого пайплайна оценки робастности сегментации в adverse-условиях и в систематическом сравнении эффектов методических улучшений. В дальнейшем планируется расширить анализ за счет дополнительных абляций и, при наличии ресурсов, провести пилотный UDA-эксперимент как отдельный дополнительный блок.

8. Приложения

8.1. Детальные таблицы метрик

В приложении приводятся расширенные таблицы overall/per-condition/per-class метрик для всех рассматриваемых моделей и этапов экспериментов.

8.2. Дополнительные визуализации предсказаний

В приложении представлены примеры предсказаний моделей в различных погодных и световых условиях, включая типовые случаи успешной сегментации и характерные ошибки.

8.3. Конфигурации экспериментов и параметры запусков

В приложении фиксируются ключевые параметры запусков (модель, размер входа, функция потерь, аугментации, оптимизатор, scheduler, критерий checkpoint) и ссылки на соответствующие эксперименты в системе логирования.

Список использованной литературы

[1] Liang-Chieh Chen и др. “Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation”. В: *arXiv preprint arXiv:1802.02611* (2018). URL: https://arxiv.org/abs/1802.02611.

[2] Enze Xie и др. “SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers”. В: *Advances in Neural Information Processing Systems* 34 (2021), с. 12077—12090. URL: https://proceedings.neurips.cc/paper_files/paper/2021/file/64f1f27bf1b4ec22924fd0acb550c235-Paper.pdf.

[3] Wenhai Wang и др. “InternImage: Exploring Large-Scale Vision Foundation Models with Deformable Convolutions”. В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, с. 14408—14419. URL: https://openaccess.thecvf.com/content/CVPR2023/papers/Wang_InternImage_Exploring_Large-Scale_Vision_Foundation_Models_With_Deformable_Convolutions_CVPR_2023_paper.pdf.

[4] Maxime Oquab и др. “DINOv2: Learning Robust Visual Features without Supervision”. В: *arXiv preprint arXiv:2304.07193* (2023).