

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

**Программа подготовки бакалавров по направлению
Компьютерные науки и технологии**

Пестов Лев Евгеньевич

КУРСОВАЯ РАБОТА

Разработка системы семантической сегментации дорожной сцены с акцентом
на сегментацию слабоконтрастных объектов

Научный руководитель
преподаватель НИУ ВШЭ - НН
Сенников Андрей Олегович

Нижний Новгород, 2026г.

Оглавление

Введение	5
Глава 1. Теоретические основы семантической сегментации и доменной устойчивости	7
1.1 Семантическая сегментация дорожной сцены	7
1.1.1 Формализация задачи pixel-wise классификации	7
1.1.2 Основные метрики: mIoU, class-wise IoU, Pixel Accuracy	8
1.2 Архитектурные подходы	10
1.2.1 CNN-подходы (DeepLabV3+ как классический baseline) .	10
1.2.2 Transformer-подходы (SegFormer)	10
1.2.3 CNN-based foundation backbones (InternImage)	11
1.2.4 <i>Foundation</i> -бэкбоны в сегментации (DINOv2)	11
1.3 Domain Shift: DG, UDA, FDA — термины и различия	12
1.3.1 DG (Domain Generalization): обучение без target-домена .	12
1.3.2 UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target	13
1.3.3 FDA (Fourier Domain Adaptation): частотная техника адаптации	13
1.3.4 Основной сценарий: source-only / DG-style	14
1.4 Обзор литературы и SOTA-контекст	15
1.4.1 Лидерборд Cityscapes→ACDC: что показывают UDA- методы	15
1.4.2 Какие идеи можно перенести в DG-постановку	15
1.4.3 Ограничения сопоставления DG-результатов с UDA- рейтинговыми результатами	16
Глава 2. Данные, постановка переноса и схема экспериментов	17
2.1 Наборы данных и домены исследования	17
2.1.1 Cityscapes как исходный домен	17
2.1.2 ACDC как целевой домен: fog, night, rain, snow	17
2.1.3 Классы сегментации, разметка и подготовка данных . .	17
2.2 Метрики и критерии сравнения	18
2.2.1 Overall mIoU и Pixel Accuracy	18

2.2.2	Per-condition mIoU для fog, night, rain и snow	18
2.2.3	Class-wise IoU и качественные примеры	19
Глава 3.	Реализация экспериментального пайплайна	20
3.1	Технический стек и организация запусков	20
3.1.1	Обучение, логирование и выбор checkpoint	20
3.1.2	Аугментации и подготовка батчей	20
3.2	Архитектуры моделей	21
3.2.1	DeepLabV3+ и InternImage-Tiny как базовые ориентиры	21
3.2.2	SegFormer-B2	21
3.2.3	DINOv2-Small	22
Глава 4.	Результаты source-only экспериментов	23
4.1	Сравнение архитектур в E0	23
4.1.1	Общая таблица метрик на ACDC	23
4.1.2	Выбор моделей для основной серии	23
4.2	Динамика E0–E4 для DINOv2-Small	24
4.2.1	Overall и per-condition динамика	24
4.2.2	Лучший этап и откат на E4	24
4.3	Динамика E0–E4 для SegFormer-B2	25
4.3.1	Изменение метрик по этапам	25
4.3.2	Сравнение с DINOv2-Small	25
4.4	Ошибки по условиям и классам	26
4.4.1	Night как самый сложный поддомен	26
4.4.2	Class-wise IoU и визуальные примеры	26
Глава 5.	UDA-lite эксперименты на DINOv2-Small	28
5.1	U1: self-training на pseudo-labels	28
5.1.1	Построение pseudo-labels для ACDC	28
5.1.2	Дообучение и результат U1	29
5.2	U2: EMA teacher и ClassMix	29
5.2.1	EMA teacher для online pseudo-labeling	29
5.2.2	ClassMix и результат U2	30
5.3	Сравнение E3, U1 и U2	30
5.3.1	Итоговые метрики	30

5.3.2	Изменение качества по погодным условиям	31
Глава 6.	Обсуждение результатов и ограничений	32
6.1	Основные экспериментальные выводы	32
6.1.1	Архитектура как главный фактор качества	32
6.1.2	Эффект source-only модификаций	32
6.1.3	Вклад UDA-lite	32
6.2	Ограничения исследования	33
6.2.1	Ограниченное число повторных запусков	33
6.2.2	ACDC validation и границы сопоставимости	33
6.3	Рекомендации по использованию результатов	33
6.3.1	Выбор режима обучения	33
6.3.2	Направления дальнейшей проверки	34
	Заключение	35
	Список использованной литературы	36
	Приложение 1. Сводные таблицы метрик и class-wise IoU	38
	Приложение 2. Визуализации предсказаний и параметры запусков	39

Введение

Актуальность темы. Системы автономного вождения и помощи водителю (ADAS) предъявляют высокие требования к устойчивости алгоритмов компьютерного зрения. Современные методы семантической сегментации демонстрируют высокие показатели качества ($mIoU > 80\%$) на стандартных бенчмарках, включая Cityscapes, где изображения обычно получены при хорошем освещении и благоприятной погоде. В реальной дорожной сцене часто возникают туман, дождь, снегопад, сумерки и ночное освещение. Эти факторы снижают контрастность объектов и ухудшают качество моделей, обученных на данных с нормальной видимостью.

Наиболее критичны ошибки на слабоконтрастных объектах: пешеходах в темной одежде, велосипедистах и удаленных транспортных средствах, сливающихся с фоном. Для ADAS такие ошибки повышают риск неверной оценки дорожной обстановки. Сбор и пиксельная разметка данных для всех погодных условий требуют значительных ресурсов, поэтому в работе рассматриваются методы переноса моделей из домена нормальной видимости в домены со сложными условиями съемки без полной переразметки данных.

Проблема исследования заключается в существенном падении точности (Domain Shift) современных алгоритмов семантической сегментации при переходе от домена с хорошей видимостью к домену с неблагоприятными погодными условиями, особенно в части распознавания малых и слабоконтрастных объектов.

Цель работы состоит в разработке и исследовании методики повышения качества семантической сегментации дорожных сцен в сложных погодных условиях (туман, ночь, дождь) с использованием методов доменной адаптации и модификации процесса обучения.

Для достижения поставленной цели необходимо решить следующие **задачи**:

1. Провести обзор современных архитектур нейронных сетей (CNN и Transformer-based) для задачи семантической сегментации.
2. Изучить проблему доменного сдвига (Domain Shift) и методы повышения обобщающей способности моделей (Data Augmentation, Domain

Adaptation).

3. Реализовать базовый пайплайн обучения (baseline) на наборе данных Cityscapes и оценить его качество на данных со сложными погодными условиями (ACDC).
4. Разработать и внедрить модификации (аугментации, функции потерь), направленные на улучшение распознавания слабоконтрастных объектов.
5. Провести сравнительный анализ результатов и оценить качество предложенных модификаций.

Объект исследования: алгоритмы семантической сегментации изображений дорожных сцен.

Предмет исследования: методы повышения устойчивости нейронных сетей к изменению визуальных условий (освещение, погода) и снижению контраста.

Глава 1. Теоретические основы семантической сегментации и доменной устойчивости

1.1. Семантическая сегментация дорожной сцены

1.1.1. Формализация задачи pixel-wise классификации

Семантическая сегментация представляет собой задачу плотной (pixel-wise) классификации, в которой каждому пикселю входного изображения сопоставляется метка класса из заранее заданного множества. Формально, пусть задано входное изображение $X \in \mathbb{R}^{H \times W \times C}$, где H и W — пространственные размеры изображения (высота и ширина), а C — количество каналов (обычно $C = 3$ для RGB-изображений). Пусть $\mathcal{K} = \{1, 2, \dots, K\}$ — множество целевых семантических классов, характерных для дорожной сцены (например, дорога, тротуар, здания, транспорт, пешеходы и т.д.).

Цель модели семантической сегментации (нейронной сети), параметризованной весами θ , заключается в поиске отображения f_θ :

$$f_\theta : \mathbb{R}^{H \times W \times C} \rightarrow \mathbb{R}^{H \times W \times K}, \quad (1)$$

которое преобразует входное изображение в тензор логитов $Z \in \mathbb{R}^{H \times W \times K}$. Для каждого пространственного положения (пикселя) с координатами (i, j) сеть предсказывает вектор $z_{i,j} \in \mathbb{R}^K$.

Вероятностное распределение принадлежности пикселя к каждому из K классов получается путем применения функции *softmax* вдоль канала классов:

$$p_{i,j}^{(k)} = \frac{\exp(z_{i,j}^{(k)})}{\sum_{c=1}^K \exp(z_{i,j}^{(c)})}, \quad (2)$$

где $p_{i,j}^{(k)}$ — предсказанная вероятность того, что пиксель (i, j) принадлежит классу k .

Итоговая предсказанная маска сегментации $\hat{Y} \in \mathcal{K}^{H \times W}$ формируется пу-

тем выбора класса с максимальной вероятностью для каждого пикселя:

$$\hat{y}_{i,j} = \arg \max_{k \in \mathcal{K}} p_{i,j}^{(k)}. \quad (3)$$

В процессе обучения модели наиболее распространенным функционалом потерь является средняя категориальная кросс-энтропия (Categorical Cross-Entropy, CCE). Если $y_{i,j}$ — истинная метка класса для пикселя (i, j) , представленная в виде one-hot вектора (где $y_{i,j}^{(k)} = 1$, если пиксель принадлежит классу k , и 0 иначе), то функция потерь имеет вид:

$$\mathcal{L}_{CE} = -\frac{1}{H \cdot W} \sum_{i=1}^H \sum_{j=1}^W \sum_{k=1}^K y_{i,j}^{(k)} \log \left(p_{i,j}^{(k)} \right). \quad (4)$$

В отличие от классификации изображений и детектирования объектов, сегментация требует одновременно семантической точности и точной локализации границ. В задачах автономного вождения модель должна выделять крупные структуры дорожной сцены и малые слабоконтрастные объекты, включая удаленных пешеходов и дорожные знаки. Поэтому качество сегментации чувствительно к доменному сдвигу (domain shift) между распределением обучающих данных (source domain) и распределением данных в целевом сценарии (target domain), например при изменении погоды или времени суток.

1.1.2. Основные метрики: mIoU, class-wise IoU, Pixel Accuracy

Для количественной оценки качества моделей семантической сегментации используются метрики, основанные на вычислении площадей перекрытия предсказанных и истинных масок. В основе вычислений лежат базовые элементы матрицы ошибок (Confusion Matrix), рассчитываемые независимо для каждого класса k :

- TP_k (True Positives) — количество истинно-положительных пикселей (пиксели, верно отнесенные к классу k);
- FP_k (False Positives) — количество ложно-положительных пикселей (пиксели, ошибочно отнесенные к классу k);
- FN_k (False Negatives) — количество ложно-отрицательных пикселей

(пиксели класса k , отнесенные моделью к другому классу);

- TN_k (True Negatives) — количество истинно-отрицательных пикселей (пиксели других классов, корректно не отнесенные к классу k).

Основная метрика качества в работе — **mIoU** (mean Intersection over Union, среднее пересечение над объединением). Сначала вычисляется **class-wise IoU** для каждого класса k : отношение площади пересечения предсказанной маски и ground truth маски к площади их объединения:

$$\text{IoU}_k = \frac{TP_k}{TP_k + FP_k + FN_k}. \quad (5)$$

Значение IoU_k лежит в диапазоне от 0 до 1. Анализ class-wise IoU показывает, на каких классах модель ошибается чаще всего. В дорожных сценах к таким классам часто относятся *bicycle*, *fence* и *pole*: они занимают малую площадь и имеют сложную геометрию.

Интегральная метрика mIoU рассчитывается как арифметическое среднее значений IoU по всем K классам:

$$\text{mIoU} = \frac{1}{K} \sum_{k=1}^K \text{IoU}_k. \quad (6)$$

В отличие от простой пиксельной точности, mIoU устойчивее к сильному дисбалансу классов, типичному для дорожных сцен: класс «дорога» может занимать значительную часть изображения, а класс «светофор» — менее долей процента.

Дополнительно в работе используется базовая метрика **Pixel Accuracy (PA)** — доля корректно классифицированных пикселей по отношению к общему числу пикселей изображения:

$$\text{PA} = \frac{\sum_{k=1}^K TP_k}{\sum_{k=1}^K (TP_k + FP_k + FN_k + TN_k)} = \frac{\sum_{i=1}^H \sum_{j=1}^W \mathbb{I}(\hat{y}_{i,j} = y_{i,j})}{H \cdot W}, \quad (7)$$

где $\mathbb{I}(\cdot)$ — индикаторная функция, равная 1 при выполнении условия и 0 в противном случае. Хотя PA легко интерпретируется, она может быть обманчиво высокой при доминировании фоновых классов, поэтому используется лишь в качестве вспомогательного индикатора.

Для оценки устойчивости моделей в *adverse*-условиях метрики отдельно агрегируются по подмножествам целевого датасета: *fog, night, rain, snow* в ACDC. Такое разбиение показывает, при каких погодных и оптических искажениях качество сегментации снижается сильнее.

1.2. Архитектурные подходы

1.2.1. CNN-подходы (DeepLabV3+ как классический baseline)

Сверточные архитектуры долгое время оставались основным классом моделей для семантической сегментации. В работе в качестве классического подхода рассматривается **DeepLabV3+** [1], сочетающая энкодер-декодерную схему, модуль *Atrous Spatial Pyramid Pooling* и *dilated* свертки для расширения эффективного рецептивного поля без потери разрешения признаков. Такая архитектура учитывает контекст на нескольких масштабах и уточняет границы объектов, что важно для дорожных сцен с тонкими структурами и малыми объектами. В оригинальной статье авторы сообщают о результате **82.1% mIoU** на тестовом наборе *Cityscapes* и **89.0% mIoU** на *PASCAL VOC 2012* без дополнительного *post-processing*. Здесь DeepLabV3+ используется как CNN-baseline для сравнения с трансформерными и foundation-подходами.

1.2.2. Transformer-подходы (SegFormer)

SegFormer [2] относится к эффективным трансформерным архитектурам для семантической сегментации. Модель использует иерархический энкодер, который формирует признаки на нескольких масштабах без позиционного кодирования, и легкий MLP-декодер. Декодер объединяет разномасштабные признаки для построения итоговой маски, сохраняя баланс между качеством сегментации и вычислительной сложностью. В оригинальной статье конфигурация *SegFormer-B5* достигает **84.0% mIoU** на тестовом наборе *Cityscapes*, а вариант *SegFormer-B4* показывает **51.8% mIoU** на *ADE20K*. В работе используется конфигурация *SegFormer-B2*, реализованная через библиотеку *segmentation_models_pytorch*; она выступает сильным трансформерным baseline и не относится к foundation-моделям в строгом смысле.

1.2.3. CNN-based foundation backbones (InternImage)

InternImage [3] представляет собой CNN-based foundation-модель, в которой в качестве основного оператора используется *DCNv3* — деформируемая свертка с большим эффективным рецептивным полем и адаптивным пространственным агрегированием признаков. Архитектура строится как иерархический четырехстадийный бэкбон, а ее блоки сочетают свойства современных CNN и transformer-подобный дизайн, включая *Layer Normalization*, *feed-forward network* и *GELU*. Поэтому InternImage рассматривается как промежуточный вариант между классическими сверточными сетями и крупными vision foundation models.

1.2.4. Foundation-бэкбоны в сегментации (DINOv2)

Foundation-подходы используют предварительное обучение на масштабных и разнообразных наборах изображений без разметки (*self-supervised learning*), что существенно повышает переносимость признаков между различными доменами и задачами. **DINOv2 [4]** — современная архитектура на базе *Vision Transformer*, которая благодаря обучению с дистилляцией и специальным целевым функциям формирует богатые универсальные визуальные представления. В оригинальной статье показано, что даже замороженный бэкбон DINOv2 в связке с *ViT-Adapter* достигает **60.2% mIoU** на *ADE20K*, **86.9% mIoU** на *Cityscapes* и **89.0% mIoU** на *Pascal VOC*.

DINOv2-Small используется для проверки гипотезы о том, что предобученные универсальные признаки повышают устойчивость сегментации при низкой видимости, низком контрасте и сложной погоде. Для плотного предсказания поверх замороженного или дообучаемого (fine-tuning) бэкбона DINOv2 применяется легковесный линейный декодер (*LinearDecoder*). Он преобразует последовательность патч-токенов в двумерное пространственное представление и восстанавливает признаки до исходного разрешения изображения с помощью билинейной интерполяции.

1.3. Domain Shift: DG, UDA, FDA — термины и различия

При сегментации дорожных сцен качество модели на обучающем распределении и в новом визуальном домене может существенно различаться. Исходный домен в работе — Cityscapes [5]: городские сцены при сравнительно благоприятной видимости. Целевой домен — ACDC [6]: туман, ночь, дождь и снег. Доменный сдвиг формально записывается как

$$P_s(X, Y) \neq P_t(X, Y), \quad (8)$$

где P_s и P_t — распределения исходного и целевого доменов, X — изображение, Y — карта меток. В попиксельной задаче сдвиг затрагивает цвет, контраст, видимость границ, различимость мелких классов и частоту ошибок на тонких структурах.




Рис. 1 – Различие между DG, UDA и FDA с точки зрения доступа к целевому домену и основной идеи метода.

1.3.1. DG (Domain Generalization): обучение без target-домена

Domain Generalization (DG) обучает модель на одном или нескольких исходных доменах без какого-либо доступа к target-данным. Цель — не подстройка под конкретный набор, а признаки, которые слабо зависят от условий съемки. Такая постановка анализируется в обзоре [7].

Эксперименты **E0–E4** соответствуют source-only / DG-style постановке: разметка берется только из Cityscapes, а ACDC используется для проверки переноса. Weather-аугментации и частотные преобразования применяются к source-изображениям и не задействуют ACDC при обучении.

1.3.2. UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target

Unsupervised Domain Adaptation (UDA) в отличие от DG получает на этапе обучения неразмеченные изображения целевого домена. Разметка Y_t недоступна, но X_t хватает, чтобы оценивать target-статистику и подстраивать модель. Классическим инструментом было adversarial-выравнивание признаков [8]; современные подходы для сегментации опираются на *self-training*, *pseudo-labels* и стабилизирующие приемы.

Базовая схема pseudo-label self-training отбирает только уверенные пиксели:

$$\hat{y}_t^{(i,j)} = \arg \max_k p_t^{(i,j,k)}, \quad \max_k p_t^{(i,j,k)} \geq \tau, \quad (9)$$

где τ — порог уверенности. Такой механизм не заменяет ручную разметку, но вводит в обучение информацию о структуре target-распределения. Дополнительные эксперименты **U1** и **U2** используют ACDC train без ground truth: через pseudo-labels и online teacher.

1.3.3. FDA (Fourier Domain Adaptation): частотная техника адаптации

Fourier Domain Adaptation (FDA) переносит стиль между доменами в частотной области. Низкочастотная часть амплитудного спектра отвечает за внешний вид сцены: освещение, цветовую температуру, контраст, погодный оттенок. Фаза фиксирует геометрию и положение объектов.

Преобразование Фурье представимо в виде

$$\mathcal{F}(x) = A_x \cdot e^{i\Phi_x}, \quad (10)$$

а FDA подменяет амплитуду source-изображения A_s амплитудой target-

изображения A_t в низкочастотной области:

$$\tilde{A}_s = (1 - M) \odot A_s + M \odot A_t, \quad (11)$$

где M — маска выбранной полосы спектра. После обратного преобразования получается изображение с source-разметкой и target-внешностью. В эксперименте **Е3** используется не классический FDA с ACDC, а source-only вариант: частотная модификация разнообразит стиль Cityscapes и сохраняет DG-постановку.

1.3.4. Основной сценарий: source-only / DG-style

Основная экспериментальная линия Е0–Е4 направлена на оценку переноса без участия ACDC в обучении. Модели обучаются только на разметке Cityscapes, а ACDC используется как внешняя проверка устойчивости к погоде и низкой видимости.

Таблица 1 – Различие постановок, используемых в работе

Постановка	Что доступно при обучении	Как используется в работе
Source-only / DG-style	Размеченный Cityscapes; ACDC не используется	Основная линия Е0–Е4 и сравнение архитектур на ACDC validation
UDA-lite	Размеченный Cityscapes и неразмеченный ACDC train	Дополнительные эксперименты U1 и U2 для DINOv2-Small
FDA-style	Source-изображения с частотными преобразованиями стиля	Этап Е3 как способ повышения устойчивости без target-разметки

Такая постановка соответствует практическому сценарию, когда размеченный датасет в благоприятных условиях доступен, а пиксельной разметки для нового погодного сценария нет. Основная серия экспериментов оценивает перенос Cityscapes $\rightarrow$ ACDC без target-данных при обучении. **UDA-lite** рассматривается отдельно, поскольку этот режим использует неразмеченные target-изображения.

1.4. Обзор литературы и SOTA-контекст

1.4.1. Лидерборд Cityscapes→ACDC: что показывают UDA-методы

Публичный лидерборд HyperAI *Domain Adaptation on Cityscapes to ACDC* фиксирует эту постановку как отдельный mIoU-бенчмарк [9]. Несколько характерных позиций сведены в таблицу 2.

Таблица 2 – Примеры результатов Cityscapes → ACDC по данным HyperAI

Метод	mIoU, %	Тип идеи
SoRA	78.8	современная верхняя граница таблицы
Rein	77.6	foundation-модель / domain generalization
CoDA	72.6	chain-of-domain adaptation
MIC	70.4	masked consistency
HRDA	68.0	high-resolution UDA
DAFormer	55.4	transformer-based UDA
FDA (DeepLabV2)	45.7	частотная адаптация

Методы из верхней части таблицы используют сильные backbone, pseudo-labeling, teacher-student обучение, consistency-регуляризацию и обработку изображений в высоком разрешении. Характерные примеры включают DAFormer с transformer-based архитектурой и стабилизацией self-training [10], HRDA с multi-resolution обучением [11] и MIC с masked consistency для target-изображений [12]. Во всех этих подходах при обучении доступны неразмеченные изображения ACDC. Основная серия экспериментов в работе не использует target-данные, чтобы отдельно оценить устойчивость моделей и source-only приемов.

1.4.2. Какие идеи можно перенести в DG-постановку

Из UDA-литературы используются отдельные приемы, совместимые с отсутствием target-разметки. **E2** проверяет class-balanced веса и focal-компонент на трудных классах. **E3** применяет частотные преобразования как FDA-style способ разнообразить стиль source-домена. **E4** добавляет consistency-регуляризацию только в source. Pseudo-labeling вынесен в **U1–U2**, поскольку он требует неразмеченного ACDC и выходит за пределы source-only постановки.

1.4.3. Ограничения сопоставления DG-результатов с UDA-рейтинговыми результатами

Прямое сравнение с UDA-лидербордом ограничено разным уровнем доступа к данным: лидерборд использует target-изображения в обучении, а E0–E4 используют ACDC только для оценки. Поэтому source-only этапы интерпретируются отдельно, а U1–U2 рассматриваются как UDA-lite расширение основной серии.

Глава 2. Данные, постановка переноса и схема экспериментов

2.1. Наборы данных и домены исследования

2.1.1. Cityscapes как исходный домен

Исходный домен — Cityscapes [5], базовый набор для сегментации городских сцен. Модель обучается на его размеченных кадрах в благоприятных условиях и проверяется на более сложном target-домене. Такая схема задает строгую проверку переноса: source-domain покрывает дневную съемку без осадков, а оценка проводится на изображениях с другим освещением и погодой.

2.1.2. ACDC как целевой домен: fog, night, rain, snow

Целевой домен — ACDC [6], четыре неблагоприятных условия: *fog*, *night*, *rain*, *snow*. Разбиение по условиям дает возможность анализировать ошибку по типам сдвига, а не только по одному усредненному числу.

На рис. 2 приведены примеры из обоих наборов. Различия между доменами затрагивают яркость, текстуры, насыщенность, видимость дальних объектов и надежность границ между классами.




Рис. 2 – Примеры визуального сдвига между Cityscapes и погодными условиями ACDC

2.1.3. Классы сегментации, разметка и подготовка данных

Оба набора приводятся к стандартной 19-классовой схеме Cityscapes. На вход идут RGB-изображения и маски в формате *trainId*; void-области (255) исключены из функции потерь и из расчета IoU.

Препроцессинг включает приведение к единому формату, согласованные

геометрические преобразования изображения и маски и нормализацию под выбранную архитектуру. В основной линии E0–E4 ACDC выступает только тестовым доменом, его неразмеченные изображения подключаются исключительно в U1–U2.

2.2. Метрики и критерии сравнения

2.2.1. Overall mIoU и Pixel Accuracy

Основной числовой критерий — overall mIoU на ACDC validation. По нему сравниваются архитектуры в E0 и динамика этапов E1–E4, U1 и U2. Усреднение по классам снижает влияние дисбаланса: дорога и небо занимают на порядок больше пикселей, чем светофор или знак, поэтому одна пиксельная точность слабо характеризует качество переноса.

Усреднение ведется по $K = 19$ обучаемым классам:

$$\text{mIoU}_{\text{overall}} = \frac{1}{K} \sum_{k=1}^K \text{IoU}_k. \quad (12)$$

Pixel Accuracy используется как вспомогательная метрика. Она показывает долю верно классифицированных пикселей и фиксирует грубую деградацию модели, но высокая PA может скрывать ошибки на малых и слабоконтрастных классах.

$$\text{PA} = \frac{1}{|\Omega|} \sum_{(i,j) \in \Omega} \mathbb{I}(\hat{y}_{i,j} = y_{i,j}), \quad (13)$$

где Ω — множество валидных пикселей без игнорируемой разметки.

2.2.2. Per-condition mIoU для fog, night, rain и snow

ACDC валидация разбита по четырем условиям, поэтому для каждой модели отдельно считается per-condition mIoU. Усреднение по всему ACDC скрывает, на каком сдвиге случился прирост: улучшение overall mIoU может опираться целиком на туман и снег при сохранении провала ночью.

Для условия $c \in \{\text{fog}, \text{night}, \text{rain}, \text{snow}\}$ метрика считается на соответствую-

ющем подмножестве D_c :

$$\text{mIoU}_c = \frac{1}{K} \sum_{k=1}^K \text{IoU}_k(D_c). \quad (14)$$

2.2.3. Class-wise IoU и качественные примеры

Class-wise IoU используется для диагностики классов, дающих основной вклад в ошибку. Крупные области обычно сегментируются стабильнее, а тонкие и редкие классы сильнее страдают от доменного сдвига, поэтому группа слабо-контрастных и малых объектов анализируется отдельно.

$$\text{IoU}_k = \frac{TP_k}{TP_k + FP_k + FN_k}. \quad (15)$$

Качественные примеры служат дополнением к метрикам. Визуализации показывают типы ошибок: пропуск объекта, смешение близких классов, разрыв тонких структур, потерю границ в тумане, ночью, под дождем и снегом.

Глава 3. Реализация экспериментального пайплайна

Все эксперименты оформлены как набор Jupyter-ноутбуков, разнесенных по назначению: обучение, генерация pseudo-labels, отдельная оценка на ACDC.

3.1. Технический стек и организация запусков

Основной стек: **PyTorch** для моделей и функций потерь, **PyTorch Lightning** для тренировочного цикла, **Albumentations** для синхронных преобразований изображения и маски, **TorchMetrics** для расчета IoU, **ClearML** для логирования гиперпараметров, графиков и ссылок на checkpoints.

Экспериментальный пайплайн состоит из трех этапов. Модель обучается на Cityscapes в одном из сценариев E0–E4. Затем выбранный checkpoint загружается в evaluation-ноутбук и оценивается на ACDC validation. Для UDA-lite добавляется промежуточный этап: pseudo-labels для ACDC train либо предвычисляются в U1, либо генерируются онлайн внутри цикла обучения в U2.

3.1.1. Обучение, логирование и выбор checkpoint

Каждый train-ноутбук фиксирует конфигурацию запуска: архитектуру, размер входа, число классов, optimizer, learning rate, batch size, состав аугментаций и путь сохранения весов. В процессе логируются train/val loss, mIoU и служебные параметры. За счет этого этапы E0–E4 сравниваются по сохраненным параметрам запусков.

Checkpoint отбирается по validation mIoU на валидационной части обучающего сценария. После выбора весов модель загружается в отдельный evaluation-ноутбук, а таблицы формируются по результатам единого контура оценки на ACDC.

3.1.2. Аугментации и подготовка батчей

Батч строится вокруг пары «RGB-изображение — маска». Геометрические преобразования применяются синхронно, фотометрические — только к изображению, чтобы не нарушать соответствие пикселей и классов. На выходе маска

остаётся в *trainId*, изображение нормализуется и переводится в тензор.

Базовый набор — стандартный *resize/crop* и нормализация. Этапы E1–E3 добавляют изменения контраста, яркости, погодного стиля и частотную модификацию амплитудного спектра. E4 устроен иначе: для одного *source*-примера формируются *weak/strong*-представления, между предсказаниями вводится *consistency*-регуляризация.

3.2. Архитектуры моделей

В работе сравниваются четыре группы моделей разной сложности: классический CNN, современный *convolutional backbone*, *transformer-based baseline* и *foundation-бэкбон*. Эти модели задают уровни качества для последующих экспериментов.

3.2.1. DeepLabV3+ и InternImage-Tiny как базовые ориентиры

DeepLabV3+ [1] играет роль CNN-baseline. Он показывает, насколько проседает перенос Cityscapes → ACDC у классической сегментационной архитектуры без специальных механизмов устойчивости.

InternImage-Tiny [3] используется как современная *convolutional* архитектура с DCNv3-блоками. Сравнение с ним показывает вклад более выразительного *backbone* относительно вкладов DG/UDA-приемов.

3.2.2. SegFormer-B2

SegFormer-B2 [2] используется как основной *transformer-based baseline*. Он проходит те же этапы E0–E4, что и DINOv2-Small; поэтому на нем проверяется, сохраняются ли эффекты аугментаций, *class-balanced loss* и *frequency-style преобразований* для другой архитектуры.

SegFormer-B2 задает уровень качества стандартной сегментационной модели при тех же данных и близком тренировочном цикле. Такое сравнение помогает отделить вклад *foundation-признаков* DINOv2 от вклада изменений в обучении.

3.2.3. DINOv2-Small

DINOv2-Small [4] — основная модель исследования. В реализации backbone подгружается как предобученный, поверх него обучается легковесный декодер на 19 классов Cityscapes. Такая связка проверяет, насколько универсальные self-supervised признаки помогают переносу на ACDC без target-разметки.

Полная серия запусков E0–E4 и UDA-lite расширения U1–U2 выполнена для DINOv2-Small. Основанием для выбора стал результат E0: DINOv2 оказался наиболее сильной исходной архитектурой, поэтому последующие модификации пайплайна проверялись прежде всего на нем.

Глава 4. Результаты source-only экспериментов

4.1. Сравнение архитектур в E0

4.1.1. Общая таблица метрик на ACDC

Таблица 3 – Baseline E0: перенос Cityscapes → ACDC validation

Модель	mIoU	PA	Fog	Night	Rain	Snow
DeepLabV3+	0.3015	0.7204	0.4422	0.1363	0.3293	0.3215
InternImage-Tiny	0.3899	0.7735	0.5380	0.2137	0.4308	0.3997
SegFormer-B2	0.4463	0.7685	0.5820	0.2461	0.4722	0.4553
DINOv2-Small	0.5436	0.8575	0.6882	0.3350	0.5263	0.5816

Разброс между архитектурами в E0 заметный. DeepLabV3+ и InternImage-Tiny показывают худшие значения по каждому условию. SegFormer-B2 превосходит классические baseline. Наибольшее качество в этом сравнении показывает DINOv2-Small: overall mIoU выше SegFormer-B2 на 0.0973, на ночи разрыв ещё заметнее (0.3350 против 0.2461).

4.1.2. Выбор моделей для основной серии

Этапы E1–E4 проводятся для двух моделей: DINOv2-Small и SegFormer-B2. DINOv2-Small выбран как лучшая модель E0. SegFormer-B2 используется как контрольная transformer-архитектура, чтобы проверить, связаны ли эффекты E1–E4 только с foundation-бэкбоном.

4.2. Динамика E0–E4 для DINOv2-Small

4.2.1. Overall и per-condition динамика

Таблица 4 – DINOv2-Small: source-only этапы E0–E4 на ACDC validation

Этап	mIoU	PA	Fog	Night	Rain	Snow
E0	0.5436	0.8575	0.6882	0.3350	0.5263	0.5816
E1	0.5620	0.8690	0.6940	0.3506	0.5540	0.5963
E2	0.5609	0.8642	0.6810	0.3510	0.5507	0.5977
E3	0.5711	0.8826	0.6977	0.3823	0.5542	0.6004
E4	0.5622	0.8727	0.6879	0.3605	0.5635	0.5836

Лучший source-only этап для DINOv2-Small — **E3**: overall mIoU вырастает с 0.5436 до 0.5711. Самый крупный прирост по поддомену приходится на *night*: 0.3350 → 0.3823, +0.047. Такой результат согласуется с целью работы, поскольку ночные сцены особенно чувствительны к низкому контрасту и ухудшению видимости.

4.2.2. Лучший этап и откат на E4

E1 обеспечивает устойчивый прирост над E0 за счёт фотометрических аугментаций. E2 почти не меняет overall mIoU: class-balanced loss с focal-весами улучшает часть редких классов, но одновременно снижает качество на крупных классах. E3 добавляет частотные преобразования и дает лучший source-only результат. На E4 mIoU снижается до 0.5622. Возможное объяснение связано с тем, что consistency-регуляризация применяется только в source-домене: предсказания становятся более согласованными между weak/strong-видами одного изображения, но не приближаются к target-распределению.




Рис. 3 – Динамика overall mIoU для DINOv2-Small и SegFormer-B2 в source-only экспериментах

4.3. Динамика E0–E4 для SegFormer-B2

4.3.1. Изменение метрик по этапам

Таблица 5 – SegFormer-B2: source-only этапы E0–E4 на ACDC validation

Этап	mIoU	PA	Fog	Night	Rain	Snow
E0	0.4463	0.7685	0.5820	0.2461	0.4722	0.4553
E1	0.5022	0.8273	0.6330	0.2740	0.5232	0.5272
E2	0.5001	0.8249	0.6357	0.2881	0.5293	0.5158
E3	0.5023	0.8396	0.6426	0.2899	0.5328	0.5148
E4	0.4842	0.8277	0.6258	0.2761	0.4974	0.4859

У SegFormer-B2 основной прирост приходится на E1: mIoU растёт с 0.4463 до 0.5022. E2 и E3 изменяют результат на тысячные доли, а E4 заметно снижает качество. Формально лучший этап здесь тоже E3, но преимущество над E1 находится в пределах шума одного запуска.

4.3.2. Сравнение с DINOv2-Small

DINOv2-Small превосходит SegFormer-B2 на каждом этапе. Качественная картина изменений совпадает: E1 улучшает обе модели, E3 соответствует лучшему source-only результату, E4 снижает overall mIoU. Основное различие проявляется в трудных условиях. На ночи DINOv2-Small E3 удерживает 0.3823, SegFormer-B2 E3 — 0.2899.

4.4. Ошибки по условиям и классам

4.4.1. Night как самый сложный поддомен

Night остаётся самым сложным поддоменом во всех сериях. Даже у лучшего source-only DINOv2-Small E3 ночной mIoU равен 0.3823, тогда как *fog* и *snow* находятся в районе 0.70 и 0.60. Слабое освещение ухудшает видимость границ объектов и снижает контраст между мелкими классами и фоном.

4.4.2. Class-wise IoU и визуальные примеры

Таблица 6 – Примеры class-wise IoU для трудных классов на лучших source-only этапах

Класс	DINOv2-Small E3	SegFormer-B2 E3
traffic light	0.5184	0.5639
pole	0.3888	0.4238
fence	0.3691	0.2870
bicycle	0.3314	0.2769
rider	0.1689	0.1579

Низкие значения концентрируются на тонких и редких объектах. По отдельным классам преимущество не однозначно: SegFormer-B2 заметно лучше распознаёт *traffic light* и *pole*, но проигрывает на *fence*, *bicycle* и *rider*. По всему ACDC и по большинству условий вперёд выходит DINOv2-Small E3.

На визуальных примерах (рис. 4) виден типовой профиль ошибок: крупные области восстанавливаются уверенно, провалы концентрируются на границах, тонких структурах и мелких участниках движения. Эти примеры используются как дополнение к численным метрикам и помогают интерпретировать значения mIoU.



Рис. 4 – Качественные примеры сегментации DINOv2-Small E3: изображение, ground truth и предсказание

Глава 5. UDA-lite эксперименты на DINOv2-Small

После source-only этапов отдельно проверяется постановка с дополнительной информацией о целевом домене: в обучение добавляются **неразмеченные изображения ACDC train**. Эта серия отделена от E0–E4, поскольку модель получает target-изображения, пусть и без ручной разметки.

5.1. U1: self-training на pseudo-labels

5.1.1. Построение pseudo-labels для ACDC

В U1 роль teacher играет лучшая source-only модель — DINOv2-Small E3. Она проходит по ACDC train и для каждого пикселя сохраняет предсказанный класс только при уверенности $\max_k p^{(k)} \geq \tau$ с $\tau = 0.90$. Неуверенные пиксели маркируются ignore-меткой 255 и выпадают из функции потерь. Обработывается 1600 изображений: по 400 на *fog*, *night*, *rain*, *snow*.

Таблица 7 – Статистика pseudo-labels для ACDC train в U1

Условие	Изображений	Keep ratio	Confidence kept
fog	400	0.8297	0.9920
night	400	0.6543	0.9871
rain	400	0.8018	0.9906
snow	400	0.7933	0.9897

Keep ratio просаживается на *night* (0.6543): ночные кадры хуже всего размечаются source-only моделью, поэтому teacher чаще отбрасывает неуверенные пиксели. На остальных условиях keep ratio держится в районе 0.80, средняя уверенность сохранённых пикселей — около 0.99 (рис. 5).




Рис. 5 – U1: доля сохранённых пикселей и средняя уверенность кадров ACDC train при $\tau = 0.90$

5.1.2. Дообучение и результат U1

Дообучение проводится на смеси размеченного Cityscapes и ACDC train с pseudo-labels. В качестве начальных весов используется checkpoint DINOv2-Small E3; U1 продолжает обучение модели с наилучшим source-only результатом и добавляет target-данные без ручной разметки.

На ACDC validation overall mIoU поднимается с 0.5711 до **0.5828**. Наибольший прирост приходится на *rain*: 0.5542 $\rightarrow$ 0.5898 (+0.036). Confidence-фильтр улучшает результат без архитектурных изменений.

5.2. U2: EMA teacher и ClassMix

5.2.1. EMA teacher для online pseudo-labeling

U2 заменяет фиксированный teacher на скользящее среднее. Веса EMA-teacher обновляются как $\theta_t = \alpha \theta_{t-1} + (1 - \alpha) \theta_{\text{student}}$ с $\alpha = 0.999$. Pseudo-labels формируются прямо в обучающем цикле, а порог уверенности постепенно снижается с 0.968 до 0.90.

EMA-teacher снижает зависимость от одного фиксированного teacher-снимка. На ранних итерациях порог строже отбирает target-пиксели, а к концу обучения допускает больше target-сигнала, когда student уже стабилизировался.

5.2.2. ClassMix и результат U2

К EMA-teacher добавляется ClassMix: на одном изображении смешиваются классовые регионы из source-кадра и target-кадра. Такой прием расширяет распределение комбинаций объект–фон, по которым student получает обучающий сигнал. В реализации ClassMix включается с вероятностью 0.5, обучение стар-тует от U1-checkpoint.

Итоговый overall mIoU равен **0.5957**, что является максимальным значе-нием среди всех экспериментов: +0.0129 относительно U1 и +0.0246 относи-тельно лучшего source-only этапа E3.

5.3. Сравнение E3, U1 и U2

5.3.1. Итоговые метрики

Таблица 8 – Сравнение лучшего source-only этапа и UDA-lite экспериментов

Этап	mIoU	PA	Fog	Night	Rain	Snow
E3	0.5711	0.8826	0.6977	0.3823	0.5542	0.6004
U1	0.5828	0.8867	0.7001	0.3887	0.5898	0.5977
U2	0.5957	0.8923	0.7055	0.3980	0.6058	0.6087




Рис. 6 – DINOv2-Small: переход E3 → U1 → U2 на ACDC validation. Слева — overall mIoU, справа — per-condition разбиение

В последовательности E3 → U1 → U2 качество монотонно растет (рис. 6). U2 показывает наибольшее значение overall mIoU и лучший результат по каждому из четырех поддоменов.

5.3.2. Изменение качества по погодным условиям

Самый крупный прирост относительно E3 фиксируется на *rain*: +0.0516 mIoU в U2. На *night* улучшение меньше ($0.3823 \rightarrow 0.3980$), но сохраняется на обоих UDA-lite этапах. Ночные сцены остаются наиболее сложными: *fog* и *snow* находятся выше 0.60, а *night* остаётся ниже 0.40.




Рис. 7 – Качественные примеры сегментации DINOv2-Small U1: изображение, ground truth и предсказание

Полученные результаты задают два сценария использования. При отсутствии target-данных на этапе обучения предпочтительным вариантом остается DINOv2-Small E3. При наличии неразмеченных изображений ACDC train более высокое качество показывает DINOv2-Small U2.

Глава 6. Обсуждение результатов и ограничений

6.1. Основные экспериментальные выводы

6.1.1. Архитектура как главный фактор качества

Наибольшее влияние на качество оказывает выбор архитектуры. В E0 DINOv2-Small достигает 0.5436 mIoU, SegFormer-B2 — 0.4463, InternImage-Tiny — 0.3899, DeepLabV3+ — 0.3015. Разрыв между крайними значениями превышает 0.24 overall mIoU, что больше любого прироста от source-only модификаций. Следовательно, аугментации не компенсируют ограничения слабого backbone.

6.1.2. Эффект source-only модификаций

Source-only приёмы обеспечивают умеренное, но воспроизводимое улучшение. Лучший этап E3 поднимает DINOv2-Small с 0.5436 до 0.5711 (+0.028) и SegFormer-B2 с 0.4463 до 0.5023 (+0.056). E4 не подтверждает пользу consistency-регуляризации в этой реализации: на обеих моделях overall mIoU после него падает по сравнению с E3.

В этой серии фотометрические аугментации и frequency-style преобразования повышают устойчивость переноса. Их эффект ограничен отсутствием данных из target-распределения.

6.1.3. Вклад UDA-lite

Максимальное итоговое качество достигается в UDA-lite. U1 показывает, что offline pseudo-labeling улучшает DINOv2-Small E3 (0.5711 → 0.5828). U2 с EMA-teacher и ClassMix добавляет ещё +0.013 и достигает 0.5957 mIoU. Неразмеченные изображения ACDC содержат информацию о target-распределении, недоступную source-only приемам.

Результаты UDA-lite и E0–E4 следует интерпретировать отдельно, поскольку эти серии различаются постановкой задачи и уровнем доступа к данным.

6.2. Ограничения исследования

6.2.1. Ограниченное число повторных запусков

Ключевые конфигурации запускались несколько раз, но число повторов осталось ограниченным. Доверительных интервалов нет, поэтому различия порядка нескольких тысячных mIoU следует считать шумом обучения — особенно для близких пар вроде SegFormer-B2 E1 и E3. В выводах учитываются только эффекты, заметно превышающие такой разброс: преимущество DINOv2-Small, прирост на E3 и переход к UDA-lite.

6.2.2. ACDC validation и границы сопоставимости

Все числа получены на ACDC validation. Такой протокол подходит для сопоставления этапов внутри работы, но публичные лидерборды используют закрытое test-разбиение и другие протоколы обучения, поэтому численного сравнения с ними результаты работы не подразумевают.

UDA-lite реализован только для DINOv2-Small. Перенос U1 и U2 на SegFormer-B2 требует отдельной проверки.

6.3. Рекомендации по использованию результатов

6.3.1. Выбор режима обучения

Если target-домен недоступен на этапе обучения, среди проведённых экспериментов предпочтителен DINOv2-Small E3. Он показывает лучший source-only результат и не использует ACDC при обучении. При наличии неразмеченных изображений target-домена наибольшее качество показывает DINOv2-Small U2: он лидирует по overall mIoU и по каждому из четырёх условий.

SegFormer-B2 E3 можно рассматривать как более простую альтернативу, однако по качеству переноса он заметно уступает DINOv2-Small.

6.3.2. Направления дальнейшей проверки

Дальнейшая проверка должна включать повторение ключевых запусков с несколькими seed, оценку на независимом test-разбиении и отдельный анализ ночных сцен. *Night* остаётся главным слабым местом: даже U2 поднимает его только до 0.3980 mIoU.

Также требуется проверить UDA-lite для SegFormer-B2, чтобы отделить вклад метода адаптации от вклада foundation-признаков DINOv2.

Заключение

В работе изучен перенос моделей семантической сегментации дорожных сцен из Cityscapes в ACDC: из дневной городской съёмки в сцены с туманом, ночью, дождём и снегом. Цель исследования состояла в сравнении архитектур и приёмов обучения при ограниченном доступе к target-домену.

Наибольшее качество среди baseline-архитектур показала DINOv2-Small. Уже в E0 она достигает 0.5436 mIoU на ACDC validation, опережая SegFormer-B2, InternImage-Tiny и DeepLabV3+. Дальнейшие эксперименты были сосредоточены на DINOv2 и SegFormer-B2 как контрольной transformer-based архитектуре.

Из source-only модификаций лучшим оказался этап E3 с частотными преобразованиями: DINOv2-Small поднимается до 0.5711 mIoU, SegFormer-B2 — до 0.5023. E4 устойчивого прироста не дал и на обеих моделях откатил overall mIoU ниже E3.

Серия UDA-lite показала, что неразмеченные ACDC-изображения содержат полезную информацию о target-распределении. Offline self-training на pseudo-labels (U1) поднимает DINOv2-Small E3 до 0.5828 mIoU; EMA-teacher с ClassMix (U2) достигает лучшего итогового значения — **0.5957** mIoU. Значение остаётся ниже верхних позиций лидерборда HyperAI, но подтверждает совместный вклад foundation-признаков DINOv2 и target-данных без ручной разметки.

Night остаётся самым проблемным поддоменом во всех сериях. Даже U2 удерживает на нём 0.3980 mIoU, тогда как fog, rain и snow находятся в районе 0.6–0.7. Поэтому дальнейшая работа должна включать более сильные аугментации освещения, отдельный анализ редких классов и повторные запуски с несколькими seed для оценки дисперсии.

Список использованной литературы

- [1] Liang-Chieh Chen и др. «Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation». В: *arXiv preprint arXiv:1802.02611* (2018). URL: <https://arxiv.org/abs/1802.02611>.
- [2] Enze Xie и др. «SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers». В: *Advances in Neural Information Processing Systems* 34 (2021), с. 12077—12090. URL: https://proceedings.neurips.cc/paper_files/paper/2021/file/64f1f27bf1b4ec22924fd0acb550c235-Paper.pdf.
- [3] Wenhai Wang и др. «InternImage: Exploring Large-Scale Vision Foundation Models with Deformable Convolutions». В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, с. 14408—14419. URL: https://openaccess.thecvf.com/content/CVPR2023/papers/Wang_InternImage_Exploring_Large-Scale_Vision_Foundation_Models_With_Deformable_Convolutions_CVPR_2023_paper.pdf.
- [4] Maxime Oquab и др. «DINOv2: Learning Robust Visual Features without Supervision». В: *arXiv preprint arXiv:2304.07193* (2023).
- [5] Marius Cordts и др. «The Cityscapes Dataset for Semantic Urban Scene Understanding». В: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, с. 3213—3223. URL: <https://arxiv.org/abs/1604.01685>.
- [6] Christos Sakaridis и др. «ACDC: The Adverse Conditions Dataset with Correspondences for Robust Semantic Driving Scene Perception». В: *arXiv preprint arXiv:2104.13395* (2021). URL: <https://arxiv.org/abs/2104.13395>.
- [7] Kaiyang Zhou и др. «Domain Generalization: A Survey». В: *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2022). URL: <https://arxiv.org/abs/2103.02503>.

- [8] Yaroslav Ganin и др. «Domain-Adversarial Training of Neural Networks». В: *Journal of Machine Learning Research* 17.59 (2016), с. 1—35. URL: <https://jmlr.org/papers/v17/15-239.html>.
- [9] HyperAI. *Domain Adaptation on Cityscapes to ACDC*. SOTA benchmark page. 2026. URL: <https://hyper.ai/en/sota/tasks/domain-adaptation/benchmark/domain-adaptation-on-cityscapes-to-acdc> (дата обр. 26.04.2026).
- [10] Lukas Hoyer, Dengxin Dai и Luc Van Gool. «DAFormer: Improving Network Architectures and Training Strategies for Domain-Adaptive Semantic Segmentation». В: *arXiv preprint arXiv:2111.14887* (2022). URL: <https://arxiv.org/abs/2111.14887>.
- [11] Lukas Hoyer, Dengxin Dai и Luc Van Gool. «HRDA: Context-Aware High-Resolution Domain-Adaptive Semantic Segmentation». В: *arXiv preprint arXiv:2204.13132* (2022). URL: <https://arxiv.org/abs/2204.13132>.
- [12] Lukas Hoyer и др. «MIC: Masked Image Consistency for Context-Enhanced Domain Adaptation». В: *arXiv preprint arXiv:2212.01322* (2023). URL: <https://arxiv.org/abs/2212.01322>.

Приложение 1. Сводные таблицы метрик и class-wise IoU

В основной части приведены только таблицы, нужные для интерпретации результатов. Полная агрегация метрик собрана в ноутбуке `notebooks/eval/ACDC_Eval_Metrics_Comparison.ipynb`, где доступны:

- overall mIoU и Pixel Accuracy для E0–E4, U1 и U2;
- per-condition mIoU для *fog*, *night*, *rain*, *snow*;
- приросты между соседними этапами;
- class-wise IoU из отдельных evaluation-ноутбуков.

Таблица 9 – Краткая сводка ключевых итоговых результатов

Сценарий	Лучшая модель / этап	Overall mIoU
Baseline E0	DINOv2-Small E0	0.5436
Source-only	DINOv2-Small E3	0.5711
UDA-lite offline	DINOv2-Small U1	0.5828
UDA-lite online	DINOv2-Small U2	0.5957
Лучший SegFormer	SegFormer-B2 E3	0.5023

Приложение 2. Визуализации предсказаний и параметры запусков

Качественные примеры сегментации находятся в каталоге `assets/`. В тексте использованы `dinov2_e3_segmentation_examples.png` и `dinov2_u1_segmentation_examples.png`. Эти визуализации показывают, где модель корректно выделяет крупные области, а где теряет тонкие объекты и границы.

Параметры запусков зафиксированы внутри train- и eval-ноутбуков. Основные точки входа:

- `notebooks/train/cityscapes/e3/` — лучший source-only этап;
- `notebooks/pseudo/acdc/u1/` — генерация pseudo-labels для ACDC train;
- `notebooks/train/cityscapes_acdc/u1/` — offline self-training;
- `notebooks/train/cityscapes_acdc/u2/` — EMA teacher и ClassMix;
- `notebooks/eval/acdc/` — оценка на ACDC validation.

Для воспроизводимости вместе с checkpoint сохраняется и ноутбук запуска: в нём зафиксированы размер входа, batch size, learning rate, число эпох, состав аугментаций и путь к весам.