

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук
Программа подготовки бакалавров по направлению
Компьютерные науки и технологии

Пестов Лев Евгеньевич

КУРСОВАЯ РАБОТА

Разработка системы семантической сегментации дорожной сцены с акцентом
на сегментацию слабоконтрастных объектов

Научный руководитель
преподаватель НИУ ВШЭ - НН
Сенников Андрей Олегович

Нижний Новгород, 2026г.

Структура работы

1	Введение	5
2	Теоретические основы семантической сегментации и доменной устойчивости	7
2.1	Семантическая сегментация дорожной сцены	7
2.1.1	Формализация задачи pixel-wise классификации	7
2.1.2	Основные метрики: mIoU, class-wise IoU, Pixel Accuracy . .	8
2.2	Архитектурные подходы	10
2.2.1	CNN-подходы (DeepLabV3+ как классический baseline) . .	10
2.2.2	Transformer-подходы (SegFormer)	10
2.2.3	CNN-based foundation backbones (InternImage)	10
2.2.4	<i>Foundation</i> -бэббоны в сегментации (DINOv2)	11
2.3	Domain Shift: DG, UDA, FDA — термины и различия	11
2.3.1	DG (Domain Generalization): обучение без target-домена . .	12
2.3.2	UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target	13
2.3.3	FDA (Fourier Domain Adaptation): частотная техника адаптации	13
2.3.4	Почему в данной работе основной сценарий — source-only / DG-style	14
2.4	Обзор литературы и SOTA-контекст	14
2.4.1	Лидерборд Cityscapes→ACDC: что показывают UDA-методы	14
2.4.2	Какие идеи можно перенести в DG-постановку	15
2.4.3	Ограничения сопоставления DG-результатов с UDA-рейтинговыми результатами	15

3	Данные, постановка переноса и схема экспериментов	16
3.1	Наборы данных и домены исследования	16
3.1.1	Cityscapes как исходный домен	16
3.1.2	ACDC как целевой домен: fog, night, rain, snow	16
3.1.3	Классы сегментации, разметка и подготовка данных	16
3.2	Метрики и критерии сравнения	17
3.2.1	Overall mIoU и Pixel Accuracy	17
3.2.2	Per-condition mIoU для fog, night, rain и snow	17
3.2.3	Class-wise IoU и качественные примеры	18
4	Реализация экспериментального пайплайна	18
4.1	Технический стек и организация запусков	18
4.1.1	Обучение, логирование и выбор checkpoint	18
4.1.2	Аугментации и подготовка батчей	19
4.2	Архитектуры моделей	19
4.2.1	DeepLabV3+ и InternImage-Tiny как базовые ориентиры	19
4.2.2	SegFormer-B2	20
4.2.3	DINOv2-Small	20
5	Результаты source-only экспериментов	20
5.1	Сравнение архитектур в E0	20
5.1.1	Общая таблица метрик на ACDC	20
5.1.2	Выбор моделей для основной серии	21
5.2	Динамика E0–E4 для DINOv2-Small	21
5.2.1	Overall и per-condition динамика	21
5.2.2	Лучший этап и откат на E4	21

5.3	Динамика E0–E4 для SegFormer-B2	22
5.3.1	Изменение метрик по этапам	22
5.3.2	Сравнение с DINOv2-Small	23
5.4	Ошибки по условиям и классам	23
5.4.1	Night как самый сложный поддомен	23
5.4.2	Class-wise IoU и визуальные примеры	23
6	UDA-lite эксперименты на DINOv2-Small	24
6.1	U1: self-training на pseudo-labels	24
6.1.1	Построение pseudo-labels для ACDC	24
6.1.2	Дообучение и результат U1	25
6.2	U2: EMA teacher и ClassMix	26
6.2.1	EMA teacher для online pseudo-labeling	26
6.2.2	ClassMix и результат U2	26
6.3	Сравнение E3, U1 и U2	26
6.3.1	Итоговые метрики	26
6.3.2	Изменение качества по погодным условиям	27
7	Обсуждение результатов и ограничений	28
7.1	Основные экспериментальные выводы	28
7.1.1	Архитектура как главный фактор качества	28
7.1.2	Эффект source-only модификаций	28
7.1.3	Вклад UDA-lite	28
7.2	Ограничения исследования	29
7.2.1	Один прогон и отсутствие оценки дисперсии	29
7.2.2	ACDC validation и границы сопоставимости	29

7.3	Практические рекомендации	29
7.3.1	Как использовать результаты экспериментов	29
7.3.2	Что стоит проверить следующим шагом	30
8	Заключение	30
9	Приложения	31
9.1	Сводные таблицы метрик и class-wise IoU	31
9.2	Визуализации предсказаний и параметры запусков	31
	Список использованной литературы	33

1. Введение

Актуальность темы. Развитие систем автономного вождения и помощи водителю (ADAS) требует высокой надежности алгоритмов компьютерного зрения в любых условиях эксплуатации. Современные методы семантической сегментации демонстрируют высокие показатели качества ($mIoU > 80\%$) на стандартных бенчмарках, таких как Cityscapes, содержащих изображения, полученные в благоприятных погодных условиях и при хорошем освещении. Однако реальная дорожная обстановка часто сопряжена с факторами, снижающими визуальное качество сцены: туман, дождь, снегопад, сумерки или ночное время суток. В таких условиях контрастность объектов критически снижается, что приводит к значительной деградации качества работы нейронных сетей, обученных на «чистых» данных.

Особую опасность представляет потеря детектирования слабоконтрастных объектов — пешеходов в темной одежде, велосипедистов или удаленных транспортных средств, сливающихся с фоном. Ошибка сегментации в таких случаях может привести к аварийным ситуациям. При этом сбор и разметка масштабных датасетов для всех возможных погодных условий является трудоемкой и дорогостоящей задачей. В связи с этим актуальной становится задача разработки методов адаптации моделей, обученных на качественных данных, к сложным условиям видимости без необходимости полной переразметки данных.

Проблема исследования заключается в существенном падении точности (Domain Shift) современных алгоритмов семантической сегментации при переходе от домена с хорошей видимостью к домену с неблагоприятными погодными условиями, особенно в части распознавания малых и слабоконтрастных объектов.

Цель работы — разработка и исследование методики повышения качества семантической сегментации дорожных сцен в сложных погодных условиях (туман, ночь, дождь) с использованием методов доменной адаптации и модификации процесса обучения.

Для достижения поставленной цели необходимо решить следующие **задачи**:

1. Провести обзор современных архитектур нейронных сетей (CNN и Transformer-based) для задачи семантической сегментации.
2. Изучить проблему доменного сдвига (Domain Shift) и методы повышения обобщающей способности моделей (Data Augmentation, Domain

Adaptation).

3. Реализовать базовый пайплайн обучения (baseline) на наборе данных Cityscapes и оценить его качество на данных со сложными погодными условиями (ACDC).
4. Разработать и внедрить модификации (аугментации, функции потерь), направленные на улучшение распознавания слабоконтрастных объектов.
5. Провести сравнительный анализ результатов и оценить эффективность предложенных методов.

Объект исследования: алгоритмы семантической сегментации изображений дорожных сцен.

Предмет исследования: методы повышения устойчивости нейронных сетей к изменению визуальных условий (освещение, погода) и снижению контраста.

2. Теоретические основы семантической сегментации и доменной устойчивости

2.1. Семантическая сегментация дорожной сцены

2.1.1. Формализация задачи pixel-wise классификации

Семантическая сегментация представляет собой задачу плотной (pixel-wise) классификации, в которой каждому пикселю входного изображения сопоставляется метка класса из заранее заданного множества. Формально, пусть задано входное изображение $X \in \mathbb{R}^{H \times W \times C}$, где H и W — пространственные размеры изображения (высота и ширина), а C — количество каналов (обычно $C = 3$ для RGB-изображений). Пусть $\mathcal{K} = \{1, 2, \dots, K\}$ — множество целевых семантических классов, характерных для дорожной сцены (например, дорога, тротуар, здания, транспорт, пешеходы и т.д.).

Цель модели семантической сегментации (нейронной сети), параметризованной весами θ , заключается в поиске отображения f_θ :

$$f_\theta : \mathbb{R}^{H \times W \times C} \rightarrow \mathbb{R}^{H \times W \times K}, \quad (1)$$

которое преобразует входное изображение в тензор логитов $Z \in \mathbb{R}^{H \times W \times K}$. Для каждого пространственного положения (пикселя) с координатами (i, j) сеть предсказывает вектор $z_{i,j} \in \mathbb{R}^K$.

Вероятностное распределение принадлежности пикселя к каждому из K классов получается путем применения функции *softmax* вдоль канала классов:

$$p_{i,j}^{(k)} = \frac{\exp(z_{i,j}^{(k)})}{\sum_{c=1}^K \exp(z_{i,j}^{(c)})}, \quad (2)$$

где $p_{i,j}^{(k)}$ — предсказанная вероятность того, что пиксель (i, j) принадлежит классу k .

Итоговая предсказанная маска сегментации $\hat{Y} \in \mathcal{K}^{H \times W}$ формируется путем выбора класса с максимальной вероятностью для каждого пикселя:

$$\hat{y}_{i,j} = \arg \max_{k \in \mathcal{K}} p_{i,j}^{(k)}. \quad (3)$$

В процессе обучения модели наиболее распространенным функционалом потерь является средняя категориальная кросс-энтропия (Categorical Cross-

Entropy, CCE). Если $y_{i,j}$ — истинная метка класса для пикселя (i, j) , представленная в виде one-hot вектора (где $y_{i,j}^{(k)} = 1$, если пиксель принадлежит классу k , и 0 иначе), то функция потерь имеет вид:

$$\mathcal{L}_{CE} = -\frac{1}{H \cdot W} \sum_{i=1}^H \sum_{j=1}^W \sum_{k=1}^K y_{i,j}^{(k)} \log \left(p_{i,j}^{(k)} \right). \quad (4)$$

В отличие от задач классификации изображений в целом или детектирования объектов, сегментация требует одновременно высокой семантической точности (понимания контекста сцены) и точной локализации пространственных границ объектов. Для задач автономного вождения особенно важна стабильность качества предсказаний: модель должна корректно выделять как крупные структуры (дорожное полотно, небо), так и мелкие, слабоконтрастные, но критически важные объекты (пешеходы вдали, дорожные знаки). Это делает задачу крайне чувствительной к доменному сдвигу (domain shift) между распределением данных, на которых модель обучалась (source domain), и распределением данных в реальных условиях применения (target domain), например, при изменении погодных условий или времени суток.

2.1.2. Основные метрики: mIoU, class-wise IoU, Pixel Accuracy

Для количественной оценки качества моделей семантической сегментации используются метрики, основанные на вычислении площадей перекрытия предсказанных и истинных масок. В основе вычислений лежат базовые элементы матрицы ошибок (Confusion Matrix), рассчитываемые независимо для каждого класса k :

- TP_k (True Positives) — количество истинно-положительных пикселей (пиксели, верно отнесенные к классу k);
- FP_k (False Positives) — количество ложно-положительных пикселей (пиксели, ошибочно отнесенные к классу k);
- FN_k (False Negatives) — количество ложно-отрицательных пикселей (пиксели класса k , отнесенные моделью к другому классу);
- TN_k (True Negatives) — количество истинно-отрицательных пикселей (пиксели других классов, корректно не отнесенные к классу k).

Ключевой метрикой качества в данной работе является **mIoU** (mean Intersection over Union — среднее пересечение над объединением). Сначала вычисляется метрика **class-wise IoU** для каждого отдельного класса k , которая определяется как отношение площади пересечения предсказанной маски и ground truth маски к площади их объединения:

$$\text{IoU}_k = \frac{TP_k}{TP_k + FP_k + FN_k}. \quad (5)$$

Значение IoU_k строго лежит в диапазоне от 0 до 1. Анализ class-wise IoU позволяет проводить детальную диагностику поведения модели: например, выявлять классы с исторически низким качеством распознавания (такие как *bicycle*, *fence*, *pole* из-за их малой площади и сложной геометрии).

Интегральная метрика mIoU рассчитывается как арифметическое среднее значений IoU по всем K классам:

$$\text{mIoU} = \frac{1}{K} \sum_{k=1}^K \text{IoU}_k. \quad (6)$$

В отличие от простой пиксельной точности, mIoU является робастной метрикой в условиях сильного дисбаланса классов, который типичен для дорожных сцен (где класс «дорога» может занимать значительную часть изображения, а «светофор» — менее долей процента).

Дополнительно в работе используется базовая метрика **Pixel Accuracy (PA)** — доля корректно классифицированных пикселей по отношению к общему числу пикселей изображения:

$$\text{PA} = \frac{\sum_{k=1}^K TP_k}{\sum_{k=1}^K (TP_k + FP_k + FN_k + TN_k)} = \frac{\sum_{i=1}^H \sum_{j=1}^W \mathbb{I}(\hat{y}_{i,j} = y_{i,j})}{H \cdot W}, \quad (7)$$

где $\mathbb{I}(\cdot)$ — индикаторная функция, равная 1 при выполнении условия и 0 в противном случае. Хотя PA легко интерпретируется, она может быть обманчиво высокой при доминировании фоновых классов, поэтому используется лишь в качестве вспомогательного индикатора.

Для оценки устойчивости моделей в *adverse*-условиях (неблагоприятных условиях видимости), отдельно агрегируются и анализируются метрики по специфическим подмножествам целевого датасета (например, сценарии *fog*, *night*, *rain*, *snow* в датасете ACDC). Это позволяет явно количественно оценить степень деградации сегментации для каждого типа погодного или оптического искажения.

2.2. Архитектурные подходы

2.2.1. CNN-подходы (DeepLabV3+ как классический baseline)

Сверточные архитектуры долгое время являлись основным стандартом для задачи семантической сегментации. В работе в качестве классического подхода рассматривается **DeepLabV3+** [1], сочетающая энкодер-декодерную схему, модуль *Atrous Spatial Pyramid Pooling* и *dilated* свертки для расширения эффективного рецептивного поля без потери разрешения признаков. Такой подход позволяет одновременно учитывать контекст на нескольких масштабах и уточнять границы объектов, что особенно важно для дорожных сцен с большим числом тонких структур и малых объектов. В оригинальной статье авторы сообщают о результате **82.1% mIoU** на тестовом наборе *Cityscapes* и **89.0% mIoU** на *PASCAL VOC 2012* без дополнительного post-processing. DeepLabV3+ в данной работе используется как понятный и интерпретируемый CNN-baseline для сравнения с более современными трансформерными и foundation-подходами.

2.2.2. Transformer-подходы (SegFormer)

SegFormer [2] относится к высокоэффективным трансформерным архитектурам для семантической сегментации. Особенностью архитектуры является использование иерархического энкодера, который выдает признаки на нескольких масштабах, не требуя при этом позиционного кодирования, и легкого MLP-декодера (многослойного персептрона). Декодер объединяет разномасштабные признаки для предсказания финальной маски, что обеспечивает хороший баланс между качеством сегментации и вычислительной сложностью. В оригинальной статье наиболее сильная конфигурация *SegFormer-B5* достигает **84.0% mIoU** на тестовом наборе *Cityscapes*, а вариант *SegFormer-B4* показывает **51.8% mIoU** на *ADE20K*. В данной работе используется конфигурация *SegFormer-B2* (реализованная через библиотеку `segmentation_models_pytorch`), которая представляет современный практический подход и выступает в качестве сильного трансформерного baseline, не являющегося foundation-моделью в строгом смысле.

2.2.3. CNN-based foundation backbones (InternImage)

InternImage [3] представляет собой CNN-based foundation-модель, в которой в качестве основного оператора используется *DCNv3* — деформируемая сверт-

ка, обеспечивающая большое эффективное рецептивное поле и адаптивное пространственное агрегирование признаков. Архитектура строится как иерархический четырехстадийный бэкбон, а ее блоки сочетают свойства современных CNN и transformer-подобный дизайн, включая *Layer Normalization*, *feed-forward network* и *GELU*. Благодаря этому InternImage рассматривается как важный промежуточный вариант между классическими сверточными сетями и крупными vision foundation models.

2.2.4. *Foundation*-бэкбоны в сегментации (DINOv2)

Foundation-подходы используют предварительное обучение на масштабных и разнообразных наборах изображений без разметки (*self-supervised learning*), что существенно повышает переносимость признаков между различными доменами и задачами. **DINOv2** [4] — современная архитектура на базе *Vision Transformer*, которая благодаря обучению с дистилляцией и специальным целевым функциям формирует богатые универсальные визуальные представления. В оригинальной статье показано, что даже замороженный бэкбон DINOv2 в связке с *ViT-Adapter* достигает **60.2% mIoU** на *ADE20K*, **86.9% mIoU** на *Cityscapes* и **89.0% mIoU** на *Pascal VOC*.

В рамках исследования модель **DINOv2-Small** рассматривается как основная для проверки гипотезы о том, что предобученные универсальные признаки повышают устойчивость сегментации в условиях пониженной видимости, низкого контраста и сложных погодных условий. Для решения задачи плотного предсказания (сегментации) поверх замороженного или дообучаемого (fine-tuning) бэкбона DINOv2 применяется специально разработанный легковесный линейный декодер (**LinearDecoder**). Он преобразует одномерную последовательность патч-токенов обратно в двумерное пространственное представление и с помощью билинейной интерполяции восстанавливает признаки до исходного разрешения изображения для попиксельной классификации.

2.3. *Domain Shift: DG, UDA, FDA — термины и различия*

При сегментации дорожных сцен качество модели на близких к обучающим данным и при переносе в другой визуальный домен расходится. Исходный домен в работе — Cityscapes [5]: городские сцены при сравнительно благоприятной видимости. Целевой — ACDC [6]: туман, ночь, дождь и снег. Доменный сдвиг

2.3.2. UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target

Unsupervised Domain Adaptation (UDA) в отличие от DG получает на этапе обучения неразмеченные изображения целевого домена. Разметка Y_t недоступна, но X_t хватает, чтобы оценивать target-статистику и подстраивать модель. Классическим инструментом было adversarial-выравнивание признаков [8]; современные подходы для сегментации опираются на *self-training*, *pseudo-labels* и стабилизирующие приемы.

Базовая схема pseudo-label self-training отбирает только уверенные пиксели:

$$\hat{y}_t^{(i,j)} = \arg \max_k p_t^{(i,j,k)}, \quad \max_k p_t^{(i,j,k)} \geq \tau, \quad (9)$$

где τ — порог уверенности. Ручную разметку это не заменяет, зато позволяет учитывать структуру target-распределения. Дополнительные эксперименты **U1** и **U2** построены именно так: ACDC train подключается без ground truth, через pseudo-labels и online teacher.

2.3.3. FDA (Fourier Domain Adaptation): частотная техника адаптации

Fourier Domain Adaptation (FDA) переносит стиль между доменами в частотной области. Низкочастотная часть амплитудного спектра отвечает за внешний вид сцены: освещение, цветовую температуру, контраст, погодный оттенок. Фаза фиксирует геометрию и положение объектов.

Преобразование Фурье представимо в виде

$$\mathcal{F}(x) = A_x \cdot e^{i\Phi_x}, \quad (10)$$

а FDA подменяет амплитуду source-изображения A_s амплитудой target-изображения A_t в низкочастотной области:

$$\tilde{A}_s = (1 - M) \odot A_s + M \odot A_t, \quad (11)$$

где M — маска выбранной полосы спектра. После обратного преобразования получается source-разметка с target-внешностью. Эксперимент **E3** использует не классический FDA с ACDC, а его source-only вариант: частотная модификация разнообразит стиль Cityscapes и не выводит работу за рамки DG-постановки.

2.3.4. Почему в данной работе основной сценарий — source-only / DG-style

Основная экспериментальная линия E0–E4 устроена так, чтобы измерить перенос *без* участия ACDC в обучении. Все модели видят разметку только Cityscapes, ACDC играет роль внешней проверки устойчивости к погоде и низкой видимости.

Таблица 1: Различные постановки, используемых в работе

Постановка	Что доступно при обучении	Как используется в работе
Source-only / DG-style	Размеченный Cityscapes; ACDC не используется	Основная линия E0–E4 и сравнение архитектур на ACDC validation
UDA-lite	Размеченный Cityscapes и неразмеченный ACDC train	Дополнительные эксперименты U1 и U2 для DINOv2-Small
FDA-style	Source-изображения с частотными преобразованиями стиля	Этап E3 как попытка повысить устойчивость без target-разметки

Такой выбор отражает практическую ситуацию: размеченный датасет в благоприятных условиях обычно есть, а пиксельной разметки под каждый новый погодный сценарий — нет. Сначала оценивается честный перенос Cityscapes → ACDC. **UDA-lite** рассматривается отдельно: он сильнее, но опирается на неразмеченные target-изображения, поэтому к source-only результатам его подмешивать нельзя.

2.4. Обзор литературы и SOTA-контекст

2.4.1. Лидерборд Cityscapes→ACDC: что показывают UDA-методы

Публичный лидерборд HyperAI *Domain Adaptation on Cityscapes to ACDC* фиксирует эту постановку как отдельный mIoU-бенчмарк [9]. Несколько характерных позиций сведены в таблицу 2.

Таблица 2: Примеры результатов Cityscapes $\rightarrow$ ACDC по данным HyperAI

Метод	mIoU, %	Тип идеи
SoRA	78.8	современная верхняя граница таблицы
Rein	77.6	foundation-модель / domain generalization
CoDA	72.6	chain-of-domain adaptation
MIC	70.4	masked consistency
HRDA	68.0	high-resolution UDA
DAFormer	55.4	transformer-based UDA
FDA (DeepLabV2)	45.7	частотная адаптация

Лидеры таблицы комбинируют сильный backbone, pseudo-labeling, teacher-student обучение, consistency-регуляризацию и работу с высоким разрешением. У всех у них в обучение поступают неразмеченные изображения ACDC. Основная линия данной работы намеренно строится без target-данных, чтобы отдельно измерить устойчивость моделей и source-only приемов.

2.4.2. Какие идеи можно перенести в DG-постановку

Из UDA-литературы переиспользуются не готовые пайплайны, а отдельные приемы, совместимые с отсутствием target-разметки. **E2** проверяет class-balanced веса и focal-компонент на трудных классах. **E3** использует частотные преобразования как FDA-style способ разнообразить стиль source-домена. **E4** применяет consistency-регуляризацию только в source. Pseudo-labeling вынесен в **U1–U2**: он уже требует неразмеченного ACDC и формально выводит эксперимент за пределы source-only постановки.

2.4.3. Ограничения сопоставления DG-результатов с UDA-рейтинговыми результатами

Прямое сравнение с UDA-лидербордом некорректно не по силе моделей, а по уровню доступа к данным: лидерборд использует target-изображения в обучении, а E0–E4 — только в оценке. Поэтому source-only этапы интерпретируются отдельно, а U1–U2 рассматриваются как UDA-lite расширение основной линии.

3. Данные, постановка переноса и схема экспериментов

3.1. Наборы данных и домены исследования

3.1.1. Cityscapes как исходный домен

Исходный домен — Cityscapes [5], базовый набор для сегментации городских сцен. Модель обучается на его размеченных кадрах в благоприятных условиях и проверяется на более сложном target-домене. Такая схема делает перенос достаточно строгим: source-domain покрывает только дневную съемку без осадков, а итоговая оценка ложится на изображения с другим освещением и погодой.

3.1.2. ACDC как целевой домен: fog, night, rain, snow

Целевой домен — ACDC [6], четыре неблагоприятных условия: *fog*, *night*, *rain*, *snow*. Разбиение по условиям удобно тем, что итоговую ошибку можно разложить по типам сдвига, а не сводить к одному усредненному числу.

На рис. 2 приведены примеры из обоих наборов. Видно, что разница не сводится к снижению яркости: меняются текстуры, насыщенность, видимость дальних объектов, надежность границ между классами.




Рис. 2: Примеры визуального сдвига между Cityscapes и погодными условиями ACDC

3.1.3. Классы сегментации, разметка и подготовка данных

Оба набора приводятся к стандартной 19-классовой схеме Cityscapes. На вход идут RGB-изображения и маски в формате *trainId*; void-области (255) исключены из функции потерь и из расчета IoU.

Препроцессинг включает приведение к единому формату, согласованные геометрические преобразования изображения и маски и нормализацию под выбран-

ную архитектуру. В основной линии E0–E4 ACDC выступает только тестовым доменом, его неразмеченные изображения подключаются исключительно в U1–U2.

3.2. Метрики и критерии сравнения

3.2.1. Overall mIoU и Pixel Accuracy

Основной числовой критерий — overall mIoU на ACDC validation. По нему сравниваются архитектуры в E0 и динамика этапов E1–E4, U1 и U2. Усреднение по классам сглаживает дисбаланс: дорога и небо занимают на порядок больше пикселей, чем светофор или знак, и мало диагностичны для качества переноса.

Усреднение ведется по $K = 19$ обучаемым классам:

$$\text{mIoU}_{\text{overall}} = \frac{1}{K} \sum_{k=1}^K \text{IoU}_k. \quad (12)$$

Pixel Accuracy идет как вспомогательная метрика. Она показывает долю верно классифицированных пикселей и помогает увидеть грубую деградацию модели, но сама по себе обманчива: высокая PA может скрывать провал на малых и слабоконтрастных классах.

$$\text{PA} = \frac{1}{|\Omega|} \sum_{(i,j) \in \Omega} \mathbb{I}(\hat{y}_{i,j} = y_{i,j}), \quad (13)$$

где Ω — множество валидных пикселей без игнорируемой разметки.

3.2.2. Per-condition mIoU для fog, night, rain и snow

ACDC валидация разбита по четырем условиям, поэтому для каждой модели отдельно считается per-condition mIoU. Усреднение по всему ACDC скрывает, на каком сдвиге случился прирост: улучшение overall mIoU может опираться целиком на туман и снег при сохранении провала ночью.

Для условия $c \in \{\text{fog}, \text{night}, \text{rain}, \text{snow}\}$ метрика считается на соответствующем подмножестве D_c :

$$\text{mIoU}_c = \frac{1}{K} \sum_{k=1}^K \text{IoU}_k(D_c). \quad (14)$$

3.2.3. Class-wise IoU и качественные примеры

Class-wise IoU выступает диагностической метрикой: позволяет увидеть, какие классы доминируют в ошибке. Крупные области обычно сегментируются стабильно, тонкие и редкие классы первыми проседают под доменным сдвигом, поэтому отдельно отслеживается группа слабоконтрастных и малых объектов.

$$\text{IoU}_k = \frac{TP_k}{TP_k + FP_k + FN_k}. \quad (15)$$

Качественные примеры дополняют метрики, а не заменяют их. По визуализациям удобнее различать тип ошибки: пропуск объекта, смещение близких классов, разрыв тонких структур, потерю границ в тумане, ночью, под дождем и снегом.

4. Реализация экспериментального пайплайна

Все эксперименты оформлены как набор Jupyter-ноутбуков, разнесенных по назначению: обучение, генерация pseudo-labels, отдельная оценка на ACDC.

4.1. Технический стек и организация запусков

Основной стек: **PyTorch** для моделей и функций потерь, **PyTorch Lightning** для тренировочного цикла, **Albumentations** для синхронных преобразований изображения и маски, **TorchMetrics** для расчета IoU, **ClearML** для логирования гиперпараметров, графиков и ссылок на checkpoints.

Пайплайн строится в три шага. Сначала модель обучается на Cityscapes в одном из сценариев E0–E4. Затем checkpoint подставляется в evaluation-ноутбук и оценивается на ACDC validation. Для UDA-lite добавляется промежуточный шаг: pseudo-labels для ACDC train либо предвычисляются в U1, либо генерируются онлайн внутри цикла обучения в U2.

4.1.1. Обучение, логирование и выбор checkpoint

Каждый train-ноутбук фиксирует конфигурацию запуска: архитектуру, размер входа, число классов, optimizer, learning rate, batch size, состав аугментаций,

путь сохранения весов. В процессе логируются train/val loss, mIoU и служебные параметры. Логи нужны не для красоты графиков, а чтобы потом сравнивать E0–E4 без ручного восстановления деталей эксперимента.

Checkpoint отбирается по validation mIoU на валидационной части обучающего сценария. После выбора веса не переоцениваются на глаз: модель загружается в отдельный evaluation-ноутбук, и все таблицы заполняются из единого контура оценки на ACDC.

4.1.2. Аугментации и подготовка батчей

Батч строится вокруг пары «RGB-изображение — маска». Геометрические преобразования применяются синхронно, фотометрические — только к изображению, чтобы не нарушать соответствие пикселей и классов. На выходе маска остается в *trainId*, изображение нормализуется и переводится в тензор.

Базовый набор — стандартный resize/crop и нормализация. Этапы E1–E3 добавляют изменения контраста, яркости, погодного стиля и частотную модификацию амплитудного спектра. E4 устроен иначе: для одного source-примера формируются weak/strong-представления, между предсказаниями вводится consistency-регуляризация.

4.2. Архитектуры моделей

В работе сравниваются четыре линии разной сложности: классический CNN, современный convolutional backbone, transformer-based baseline и foundation-бэкбон. Они выступают ориентирами, а не равноправными финальными решениями.

4.2.1. DeepLabV3+ и InternImage-Tiny как базовые ориентиры

DeepLabV3+ [1] играет роль CNN-baseline. Он показывает, насколько проседает перенос Cityscapes → ACDC у классической сегментационной архитектуры без специальных механизмов устойчивости.

InternImage-Tiny [3] — более современный convolutional ориентир с DCNv3-блоками. Сравнение с ним помогает отделить вклад выразительных признаков от вклада конкретных DG/UDA-приемов.

4.2.2. SegFormer-B2

SegFormer-B2 [2] — основной transformer-based baseline. Он проходит те же этапы E0–E4, что и DINOv2-Small, поэтому удобно проверять, переносятся ли эффекты аугментаций, class-balanced loss и frequency-style преобразования между типами архитектур.

Если DINOv2 выигрывает только за счет foundation-признаков, SegFormer-B2 фиксирует уровень, доступный стандартной сегментационной модели при тех же данных и схожем тренировочном цикле.

4.2.3. DINOv2-Small

DINOv2-Small [4] — основная модель исследования. В реализации backbone подгружается как предобученный, поверх него обучается легковесный декодер на 19 классов Cityscapes. Такая связка проверяет, насколько универсальные self-supervised признаки помогают переносу на ACDC без target-разметки.

Полную серию запусков (E0–E4 и UDA-lite расширения U1–U2) получила именно эта модель. Причина прагматичная: уже в E0 DINOv2 оказался сильнейшей точкой старта, поэтому дорогие модификации пайплайна испытывались прежде всего на нем.

5. Результаты source-only экспериментов

5.1. Сравнение архитектур в E0

5.1.1. Общая таблица метрик на ACDC

Таблица 3: Baseline E0: перенос Cityscapes $\rightarrow$ ACDC validation

Модель	mIoU	PA	Fog	Night	Rain	Snow
DeepLabV3+	0.3015	0.7204	0.4422	0.1363	0.3293	0.3215
InternImage-Tiny	0.3899	0.7735	0.5380	0.2137	0.4308	0.3997
SegFormer-B2	0.4463	0.7685	0.5820	0.2461	0.4722	0.4553
DINOv2-Small	0.5436	0.8575	0.6882	0.3350	0.5263	0.5816

Разброс между архитектурами в E0 заметный. DeepLabV3+ и InternImage-Tiny задают нижний ориентир и проигрывают по каждому условию. SegFormer-B2 ощутимо сильнее классических baseline. Сильнейшая стартовая точка — DINOv2-Small: overall mIoU выше SegFormer-B2 на 0.0973, на ночи разрыв ещё заметнее (0.3350 против 0.2461).

5.1.2. Выбор моделей для основной серии

Дальнейшие этапы E1–E4 проводятся для двух моделей — DINOv2-Small и SegFormer-B2. DINOv2 идет как лучшая модель E0 и основной кандидат на финальное улучшение. SegFormer-B2 остается контрольной трансформер-архитектурой: на нем проверяется, что эффекты E1–E4 не сводятся к особенностям foundation-бэббона.

5.2. Динамика E0–E4 для DINOv2-Small

5.2.1. Overall и per-condition динамика

Таблица 4: DINOv2-Small: source-only этапы E0–E4 на ACDC validation

Этап	mIoU	PA	Fog	Night	Rain	Snow
E0	0.5436	0.8575	0.6882	0.3350	0.5263	0.5816
E1	0.5620	0.8690	0.6940	0.3506	0.5540	0.5963
E2	0.5609	0.8642	0.6810	0.3510	0.5507	0.5977
E3	0.5711	0.8826	0.6977	0.3823	0.5542	0.6004
E4	0.5622	0.8727	0.6879	0.3605	0.5635	0.5836

Лучший source-only этап для DINOv2-Small — **E3**: overall mIoU вырастает с 0.5436 до 0.5711. Самый крупный прирост по поддомену приходится на *night*: $0.3350 \rightarrow 0.3823$, $+0.047$. Именно ночные сцены страдают от низкого контраста и плохой видимости сильнее всего, поэтому такой профиль улучшения хорошо ложится на цели работы.

5.2.2. Лучший этап и откат на E4

E1 даёт устойчивый прирост над E0 за счёт фотометрических аугментаций. E2 почти не меняет overall mIoU: class-balanced loss с focal-весами помогает редким

классам, но компенсирует это просадкой на крупных. Е3 добавляет частотные преобразования и оказывается лучшим source-only вариантом. Е4 откатывает mIoU до 0.5622. Самая вероятная причина — consistency-регуляризация только в source: предсказания становятся более согласованными между weak/strong-видами одной картинки, но это не приближает их к target-распределению.




Рис. 3: Динамика overall mIoU для DINOv2-Small и SegFormer-B2 в source-only экспериментах

5.3. Динамика E0–E4 для SegFormer-B2

5.3.1. Изменение метрик по этапам

Таблица 5: SegFormer-B2: source-only этапы E0–E4 на ACDC validation

Этап	mIoU	PA	Fog	Night	Rain	Snow
E0	0.4463	0.7685	0.5820	0.2461	0.4722	0.4553
E1	0.5022	0.8273	0.6330	0.2740	0.5232	0.5272
E2	0.5001	0.8249	0.6357	0.2881	0.5293	0.5158
E3	0.5023	0.8396	0.6426	0.2899	0.5328	0.5148
E4	0.4842	0.8277	0.6258	0.2761	0.4974	0.4859

У SegFormer-B2 основной скачок приходится на E1: mIoU растёт с 0.4463 до 0.5022. E2 и E3 двигают результат на тысячные доли, E4 заметно проседает. Формально лучший этап здесь тоже E3, но преимущество над E1 в пределах шума одного запуска.

5.3.2. Сравнение с DINOv2-Small

DINOv2-Small устойчиво сильнее SegFormer-B2 на каждом этапе. Качественная картина изменений совпадает: E1 помогает обоим моделям, E3 даёт лучший source-only результат, E4 ухудшает overall mIoU. Расхождение — в запасе на трудных условиях. На ночи DINOv2-Small E3 удерживает 0.3823, SegFormer-B2 E3 — 0.2899.

5.4. Ошибки по условиям и классам

5.4.1. Night как самый сложный поддомен

Night остаётся самым тяжёлым поддоменом во всех сериях. Даже у лучшего source-only DINOv2-Small E3 ночной mIoU равен 0.3823, тогда как *fog* и *snow* находятся в районе 0.70 и 0.60. Дело не только в погодных артефактах: слабое освещение разрушает границы объектов и стирает контраст между мелкими классами и фоном.

5.4.2. Class-wise IoU и визуальные примеры

Таблица 6: Примеры class-wise IoU для трудных классов на лучших source-only этапах

Класс	DINOv2-Small E3	SegFormer-B2 E3
traffic light	0.5184	0.5639
pole	0.3888	0.4238
fence	0.3691	0.2870
bicycle	0.3314	0.2769
rider	0.1689	0.1579

Низкие значения концентрируются на тонких и редких объектах. По отдельным классам преимущество не однозначно: SegFormer-B2 заметно лучше распознаёт *traffic light* и *pole*, но проигрывает на *fence*, *bicycle* и *rider*. По всему ACDC и по большинству условий вперёд выходит DINOv2-Small E3.




Рис. 4: Качественные примеры сегментации DINOv2-Small E3: изображение, ground truth и предсказание

На визуальных примерах виден типовой профиль ошибок: крупные области восстанавливаются уверенно, провалы концентрируются на границах, тонких структурах и мелких участниках движения. Качественный анализ работает в паре с mIoU и помогает интерпретировать его, а не заменяет.

6. UDA-lite эксперименты на DINOv2-Small

После source-only этапов отдельно проверяется более сильная постановка: в обучение добавляются **неразмеченные изображения ACDC train**. Эта серия не смешивается с E0–E4 в одной таблице — условия задачи разные: модель получает target-изображения, пусть и без ручной разметки.

6.1. U1: self-training на pseudo-labels

6.1.1. Построение pseudo-labels для ACDC

В U1 роль teacher играет лучшая source-only модель — DINOv2-Small E3. Она проходит по ACDC train и для каждого пикселя сохраняет предсказанный класс только при уверенности $\max_k p^{(k)} \geq \tau$ с $\tau = 0.90$. Неуверенные пиксели маркируются ignore-меткой 255 и выпадают из функции потерь. Обработывается 1600 изображений: по 400 на *fog*, *night*, *rain*, *snow*.

Таблица 7: Статистика pseudo-labels для ACDC train в U1

Условие	Изображений	Keep ratio	Confidence kept
fog	400	0.8297	0.9920
night	400	0.6543	0.9871
rain	400	0.8018	0.9906
snow	400	0.7933	0.9897

Keep ratio просаживается на *night* (0.6543): ночные кадры хуже всего размечаются source-only моделью, поэтому teacher чаще отбрасывает неуверенные пиксели. На остальных условиях keep ratio держится в районе 0.80, средняя уверенность сохранённых пикселей — около 0.99 (рис. 5).




Рис. 5: U1: доля сохранённых пикселей и средняя уверенность кадров ACDC train при $\tau = 0.90$

6.1.2. Дообучение и результат U1

Дообучение идёт на смеси размеченного Cityscapes и ACDC train с pseudo-labels. Стартом служит checkpoint DINOv2-Small E3, то есть U1 не обучает модель с нуля, а аккуратно добавляет target-сигнал поверх лучшего source-only решения.

На ACDC validation overall mIoU поднимается с 0.5711 до **0.5828**. Наибольший прирост приходится на *rain*: $0.5542 \rightarrow 0.5898$ (+0.036). Простой confidence-фильтр без архитектурных изменений уже даёт измеримый эффект.

6.2. U2: EMA teacher и ClassMix

6.2.1. EMA teacher для online pseudo-labeling

U2 заменяет фиксированный teacher на скользящее среднее. Веса EMA-teacher обновляются как $\theta_t = \alpha \theta_{t-1} + (1 - \alpha) \theta_{\text{student}}$ с $\alpha = 0.999$. Pseudo-labels формируются прямо в обучающем цикле, а порог уверенности постепенно снижается с 0.968 до 0.90.

Такой вариант меньше зависит от одного teacher-снимка. На ранних итерациях он строже отбирает target-пиксели, а к концу обучения допускает больше target-сигнала, когда student уже стабилизировался.

6.2.2. ClassMix и результат U2

К EMA-teacher добавляется ClassMix: на одной картинке смешиваются классовые регионы из source-кадра и target-кадра. Это расширяет распределение комбинаций объект-фон, на которых student видит лоссы. В реализации ClassMix включается с вероятностью 0.5, обучение стартует от U1-checkpoint.

Итоговый overall mIoU — **0.5957**. Это лучший результат среди всех экспериментов: +0.0129 к U1 и +0.0246 к лучшему source-only этапу E3.

6.3. Сравнение E3, U1 и U2

6.3.1. Итоговые метрики

Таблица 8: Сравнение лучшего source-only этапа и UDA-lite экспериментов

Этап	mIoU	PA	Fog	Night	Rain	Snow
E3	0.5711	0.8826	0.6977	0.3823	0.5542	0.6004
U1	0.5828	0.8867	0.7001	0.3887	0.5898	0.5977
U2	0.5957	0.8923	0.7055	0.3980	0.6058	0.6087




Рис. 6: DINOv2-Small: переход $E3 \rightarrow U1 \rightarrow U2$ на ACDC validation. Слева — overall mIoU, справа — per-condition разбиение

Цепочка $E3 \rightarrow U1 \rightarrow U2$ даёт монотонный прирост (рис. 6): каждое изменение пайплайна увеличивает overall mIoU, U2 удерживает первое место по всем четырём поддоменам.

6.3.2. Изменение качества по погодным условиям

Самый крупный прирост к E3 фиксируется на *rain*: +0.0516 mIoU в U2. На *night* улучшение меньше ($0.3823 \rightarrow 0.3980$), но устойчиво на обоих UDA-lite этапах. Полностью проблему ночных сцен U2 не закрывает: туман и снег по-прежнему держатся выше 0.60, а ночной mIoU остаётся ниже 0.40.




Рис. 7: Качественные примеры сегментации DINOv2-Small U1: изображение, ground truth и предсказание

Для практической рекомендации это даёт две точки. При недоступном target-домене разумным остаётся E3. При наличии неразмеченного ACDC train — U2.

7. Обсуждение результатов и ограничений

7.1. Основные экспериментальные выводы

7.1.1. Архитектура как главный фактор качества

Главный наблюдаемый фактор — выбор архитектуры. В E0 DINOv2-Small даёт 0.5436 mIoU, SegFormer-B2 — 0.4463, InternImage-Tiny — 0.3899, DeepLabV3+ — 0.3015. Разрыв между крайними точками превышает 0.24 overall mIoU, что больше любого прироста от source-only модификаций. Слабый бэкбон одна только аугментация не компенсирует.

7.1.2. Эффект source-only модификаций

Source-only приёмы дают умеренный, но воспроизводимый эффект. Лучший этап E3 поднимает DINOv2-Small с 0.5436 до 0.5711 (+0.028) и SegFormer-B2 с 0.4463 до 0.5023 (+0.056). E4 не подтверждает пользу consistency-регуляризации в данной реализации: на обоих моделях overall mIoU после него падает по сравнению с E3.

Практический ориентир: фотометрические аугментации и frequency-style преобразования — недорогой способ повысить устойчивость переноса, но они не подменяют доступ к target-распределению.

7.1.3. Вклад UDA-lite

Самый сильный финальный результат даёт UDA-lite. U1 показывает, что offline pseudo-labeling уже улучшает DINOv2-Small E3 (0.5711 → 0.5828). U2 с EMA-teacher и ClassMix добирает ещё +0.013 и выходит на 0.5957 mIoU. Неразмеченные изображения ACDC несут информацию о target-распределении, которой source-only приёмы по построению не имеют.

Сравнивать UDA-lite с E0–E4 в одной таблице нельзя: разная постановка

задачи, разный уровень доступа к данным.

7.2. Ограничения исследования

7.2.1. Один прогон и отсутствие оценки дисперсии

Каждая конфигурация запускалась один раз. Доверительных интервалов нет, поэтому различия порядка нескольких тысячных mIoU следует считать шумом обучения — особенно для близких пар вроде SegFormer-B2 E1 и E3. Содержательно интерпретируются только устойчивые и крупные эффекты: преимущество DINOv2-Small, прирост на E3, переход к UDA-lite.

7.2.2. ACDC validation и границы сопоставимости

Все числа получены на ACDC validation. Внутреннее сравнение этапов это поддерживает, но публичные лидерборды используют закрытое test-разбиение и другие протоколы обучения, поэтому численного сравнения с ними результаты работы не подразумевают.

UDA-lite реализован только для DINOv2-Small. Перенос U1 и U2 на SegFormer-B2 требует отдельной проверки.

7.3. Практические рекомендации

7.3.1. Как использовать результаты экспериментов

Если target-домен недоступен на этапе обучения, разумный выбор — DINOv2-Small E3. Он даёт лучший source-only результат и не использует ACDC. Когда неразмеченные изображения target-домена есть, предпочтительнее DINOv2-Small U2: он лидирует по overall mIoU и по каждому из четырёх условий.

SegFormer-B2 E3 остаётся более лёгкой запасной точкой для случаев, где важна простота реализации, но по качеству переноса заметно уступает DINOv2-Small.

7.3.2. Что стоит проверить следующим шагом

Логические следующие шаги — повторение ключевых запусков с несколькими seed, оценка на независимом test-разбиении и усиление работы с ночными сценами. *Night* остаётся главным слабым местом: даже U2 поднимает его только до 0.3980 mIoU.

Полезно расширить UDA-lite на SegFormer-B2: это разведёт эффект метода и эффект foundation-признаков DINOv2.

8. Заключение

В работе изучен перенос моделей семантической сегментации дорожных сцен из Cityscapes в ACDC — из дневной городской съёмки в сцены с туманом, ночью, дождём и снегом. Цель ставилась не как погоня за лидербордом, а как прозрачное сравнение архитектур и приёмов обучения при ограниченном доступе к target-домену.

Сильнейшей baseline-архитектурой оказалась DINOv2-Small. Уже в E0 она достигает 0.5436 mIoU на ACDC validation, обгоняя SegFormer-B2, InternImage-Tiny и DeepLabV3+. Дальше эксперименты сосредоточились на DINOv2 и SegFormer-B2 как сильном контрольном baseline.

Из source-only модификаций лучшим оказался этап E3 с частотными преобразованиями: DINOv2-Small поднимается до 0.5711 mIoU, SegFormer-B2 — до 0.5023. E4 устойчивого прироста не дал и на обеих моделях откатил overall mIoU ниже E3.

Серия UDA-lite показала, что неразмеченные ACDC-изображения действительно несут полезный сигнал. Offline self-training на pseudo-labels (U1) поднимает DINOv2-Small E3 до 0.5828 mIoU; EMA-teacher с ClassMix (U2) даёт лучший итоговый результат — **0.5957** mIoU. На фоне SOTA-методов с лидерборда HuperAI это всё ещё ниже верхних позиций, но для учебной постановки результат фиксирует ожидаемое: foundation-признаки DINOv2 и аккуратное использование target-данных вместе работают лучше любого из этих компонентов по отдельности.

Night остаётся самым проблемным поддоменом во всех сериях. Даже U2 удерживает на нём 0.3980 mIoU, тогда как fog, rain и snow находятся в районе 0.6–0.7. Дальнейшее развитие работы естественно начать именно с ночных сцен:

более сильных аугментаций освещения, отдельного анализа редких классов и повторных запусков с несколькими seed для оценки дисперсии.

9. Приложения

9.1. Сводные таблицы метрик и class-wise IoU

В основной части приведены только таблицы, нужные для интерпретации результатов. Полная агрегация метрик собрана в ноутбуке `notebooks/eval/ACDC_Eval_Metrics_Comparison.ipynb`, где доступны:

- overall mIoU и Pixel Accuracy для E0–E4, U1 и U2;
- per-condition mIoU для *fog*, *night*, *rain*, *snow*;
- приросты между соседними этапами;
- class-wise IoU из отдельных evaluation-ноутбуков.

Таблица 9: Краткая сводка ключевых итоговых результатов

Сценарий	Лучшая модель / этап	Overall mIoU
Baseline E0	DINOV2-Small E0	0.5436
Source-only	DINOV2-Small E3	0.5711
UDA-lite offline	DINOV2-Small U1	0.5828
UDA-lite online	DINOV2-Small U2	0.5957
Лучший SegFormer	SegFormer-B2 E3	0.5023

9.2. Визуализации предсказаний и параметры запусков

Качественные примеры сегментации лежат в каталоге `assets/`. В тексте использованы `dinov2_e3_segmentation_examples.png` и `dinov2_u1_segmentation_examples.png`. Картинки нужны для контроля интерпретации метрик: где модель удерживает крупные области, где теряет тонкие объекты и границы.

Параметры запусков зафиксированы внутри train- и eval-ноутбуков. Основные точки входа:

- `notebooks/train/cityscapes/e3/` — лучший source-only этап;
- `notebooks/pseudo/acdc/u1/` — генерация pseudo-labels для ACDC train;
- `notebooks/train/cityscapes_acdc/u1/` — offline self-training;
- `notebooks/train/cityscapes_acdc/u2/` — EMA teacher и ClassMix;
- `notebooks/eval/acdc/` — оценка на ACDC validation.

Для воспроизводимости вместе с checkpoint сохраняется и ноутбук запуска: в нём зафиксированы размер входа, batch size, learning rate, число эпох, состав аугментаций и путь к весам.

Список использованной литературы

- [1] Liang-Chieh Chen и др. «Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation». В: *arXiv preprint arXiv:1802.02611* (2018). URL: <https://arxiv.org/abs/1802.02611>.
- [2] Enze Xie и др. «SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers». В: *Advances in Neural Information Processing Systems* 34 (2021), с. 12077—12090. URL: https://proceedings.neurips.cc/paper_files/paper/2021/file/64f1f27bf1b4ec22924fd0acb550c235-Paper.pdf.
- [3] Wenhai Wang и др. «InternImage: Exploring Large-Scale Vision Foundation Models with Deformable Convolutions». В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, с. 14408—14419. URL: https://openaccess.thecvf.com/content/CVPR2023/papers/Wang_InternImage_Exploring_Large-Scale_Vision_Foundation_Models_With_Deformable_Convolutions_CVPR_2023_paper.pdf.
- [4] Maxime Oquab и др. «DINOv2: Learning Robust Visual Features without Supervision». В: *arXiv preprint arXiv:2304.07193* (2023).
- [5] Marius Cordts и др. «The Cityscapes Dataset for Semantic Urban Scene Understanding». В: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, с. 3213—3223. URL: <https://arxiv.org/abs/1604.01685>.
- [6] Christos Sakaridis и др. «ACDC: The Adverse Conditions Dataset with Correspondences for Robust Semantic Driving Scene Perception». В: *arXiv preprint arXiv:2104.13395* (2021). URL: <https://arxiv.org/abs/2104.13395>.
- [7] Kaiyang Zhou и др. «Domain Generalization: A Survey». В: *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2022). URL: <https://arxiv.org/abs/2103.02503>.
- [8] Yaroslav Ganin и др. «Domain-Adversarial Training of Neural Networks». В: *Journal of Machine Learning Research* 17.59 (2016), с. 1—35. URL: <https://jmlr.org/papers/v17/15-239.html>.
- [9] HyperAI. *Domain Adaptation on Cityscapes to ACDC*. SOTA benchmark page. 2026. URL: <https://hyper.ai/en/sota/tasks/domain-adaptation/benchmark/domain-adaptation-on-cityscapes-to-acdc> (дата обр. 26.04.2026).