

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук
Программа подготовки бакалавров по направлению
Компьютерные науки и технологии

Пестов Лев Евгеньевич

КУРСОВАЯ РАБОТА

Разработка системы семантической сегментации дорожной сцены с акцентом
на сегментацию слабоконтрастных объектов

Научный руководитель
преподаватель НИУ ВШЭ - НН
Сенников Андрей Олегович

Нижний Новгород, 2026г.

Структура работы

1	Введение	5
2	Теоретические основы семантической сегментации и доменной устойчивости	7
2.1	Семантическая сегментация дорожной сцены	7
2.1.1	Формализация задачи pixel-wise классификации	7
2.1.2	Основные метрики: mIoU, class-wise IoU, Pixel Accuracy . .	8
2.2	Архитектурные подходы	10
2.2.1	CNN-подходы (DeepLabV3+ как классический baseline) . .	10
2.2.2	Transformer-подходы (SegFormer)	10
2.2.3	CNN-based foundation backbones (InternImage)	10
2.2.4	<i>Foundation</i> -бэббоны в сегментации (DINOv2)	11
2.3	Domain Shift: DG, UDA, FDA — термины и различия	12
2.3.1	DG (Domain Generalization): обучение без target-домена . .	12
2.3.2	UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target	12
2.3.3	FDA (Fourier Domain Adaptation): частотная техника адаптации	12
2.3.4	Почему в данной работе основной протокол — source-only / DG-style	12
2.4	Обзор литературы и SOTA-контекст	12
2.4.1	Лидерборд Cityscapes→ACDC: что показывают UDA-методы	12
2.4.2	Какие идеи можно перенести в DG-постановку	12
2.4.3	Ограничения сопоставления DG-результатов с UDA-рейтинговыми результатами	12

3	Данные и экспериментальный протокол	12
3.1	Описание датасетов	12
3.1.1	Cityscapes: структура, классы, разметка	12
3.1.2	ACDC: adverse-условия (fog/night/rain/snow), назначение в работе	12
3.2	Протокол экспериментов	12
3.2.1	Обучение на Cityscapes	12
3.2.2	Оценка на ACDC (без обучения на ACDC в основной линии)	12
3.2.3	Риски и ограничения протокола	12
3.3	Метрики и критерии сравнения	12
3.3.1	Overall mIoU и per-condition mIoU	12
3.3.2	Class-wise IoU с акцентом на трудные/слабоконтрастные классы	12
4	Реализация системы и базовый пайплайн	12
4.1	Технический стек и инфраструктура	12
4.1.1	PyTorch / PyTorch Lightning / Albumentations	12
4.1.2	Логирование экспериментов в ClearML	12
4.2	Базовый пайплайн обучения и оценки	12
4.2.1	Подготовка данных и аугментации baseline	12
4.2.2	Конфигурации обучения и выбор checkpoint	12
4.2.3	Скрипт/ноутбук оценки на ACDC	12
4.3	Исследуемые модели	12
4.3.1	DINOv2-Small (fine-tuning)	12
4.3.2	SegFormer-B2	12
4.3.3	Роль дополнительных baseline-моделей (DeepLabV3+, InternImage) как контекст	12

5	Базовые результаты и их анализ	12
5.1	Результаты baseline на Cityscapes	12
5.1.1	Сравнение моделей по валидационным метрикам	12
5.2	Cross-domain результаты на ACDC	12
5.2.1	Overall и per-condition сравнение (fog/night/rain/snow) . .	12
5.2.2	Качественный анализ ошибок и типовых провалов	12
5.3	Выводы из baseline-этапа	12
5.3.1	Почему в основную линию берутся DINOv2 и SegFormer-B2	12
5.3.2	Что baseline не решает в low-contrast сценариях	12
6	План методических улучшений	12
6.1	Экспериментальная шкала E0–E4 (накопительный протокол) . . .	12
6.1.1	E0: baseline	12
6.1.2	E1: low-contrast/weather augmentations	12
6.1.3	E2: class-balanced/focal	12
6.1.4	E3: frequency randomization (FDA-style идея без target) . .	12
6.1.5	E4: consistency regularization (weak/strong) на source	12
6.2	Две линии моделей в едином протоколе	12
6.2.1	DINOv2: ожидаемые эффекты и риски	12
6.2.2	SegFormer-B2: ожидаемые эффекты и риски	12
6.3	Отдельный подпункт о UDA (опционально)	12
6.3.1	Что такое UDA и как возможно обучение на неразмеченном ACDC	12
6.3.2	Почему UDA вынесен в дополнительный блок, а не в основной протокол	12
7	Заключение	12

7.1	Итоги по текущему этапу	12
7.2	Что выполнено и что планируется завершить	12
7.3	Практические рекомендации и дальнейшая работа	12
8	Приложения	12
8.1	Детальные таблицы метрик	12
8.2	Дополнительные визуализации предсказаний	12
8.3	Конфигурации экспериментов и параметры запусков	12
	Список использованной литературы	13

1. Введение

Актуальность темы. Развитие систем автономного вождения и помощи водителю (ADAS) требует высокой надежности алгоритмов компьютерного зрения в любых условиях эксплуатации. Современные методы семантической сегментации демонстрируют высокие показатели качества ($mIoU > 80\%$) на стандартных бенчмарках, таких как Cityscapes, содержащих изображения, полученные в благоприятных погодных условиях и при хорошем освещении. Однако реальная дорожная обстановка часто сопряжена с факторами, снижающими визуальное качество сцены: туман, дождь, снегопад, сумерки или ночное время суток. В таких условиях контрастность объектов критически снижается, что приводит к значительной деградации качества работы нейронных сетей, обученных на «чистых» данных.

Особую опасность представляет потеря детектирования слабоконтрастных объектов — пешеходов в темной одежде, велосипедистов или удаленных транспортных средств, сливающихся с фоном. Ошибка сегментации в таких случаях может привести к аварийным ситуациям. При этом сбор и разметка масштабных датасетов для всех возможных погодных условий является трудоемкой и дорогостоящей задачей. В связи с этим актуальной становится задача разработки методов адаптации моделей, обученных на качественных данных, к сложным условиям видимости без необходимости полной переразметки данных.

Проблема исследования заключается в существенном падении точности (Domain Shift) современных алгоритмов семантической сегментации при переходе от домена с хорошей видимостью к домену с неблагоприятными погодными условиями, особенно в части распознавания малых и слабоконтрастных объектов.

Цель работы — разработка и исследование методики повышения качества семантической сегментации дорожных сцен в сложных погодных условиях (туман, ночь, дождь) с использованием методов доменной адаптации и модификации процесса обучения.

Для достижения поставленной цели необходимо решить следующие **задачи**:

1. Провести обзор современных архитектур нейронных сетей (CNN и Transformer-based) для задачи семантической сегментации.
2. Изучить проблему доменного сдвига (Domain Shift) и методы повышения обобщающей способности моделей (Data Augmentation, Domain

Adaptation).

3. Реализовать базовый пайплайн обучения (baseline) на наборе данных Cityscapes и оценить его качество на данных со сложными погодными условиями (ACDC).
4. Разработать и внедрить модификации (аугментации, функции потерь), направленные на улучшение распознавания слабоконтрастных объектов.
5. Провести сравнительный анализ результатов и оценить эффективность предложенных методов.

Объект исследования: алгоритмы семантической сегментации изображений дорожных сцен.

Предмет исследования: методы повышения устойчивости нейронных сетей к изменению визуальных условий (освещение, погода) и снижению контраста.

2. Теоретические основы семантической сегментации и доменной устойчивости

2.1. Семантическая сегментация дорожной сцены

2.1.1. Формализация задачи pixel-wise классификации

Семантическая сегментация представляет собой задачу плотной (pixel-wise) классификации, в которой каждому пикселю входного изображения сопоставляется метка класса из заранее заданного множества. Формально, пусть задано входное изображение $X \in \mathbb{R}^{H \times W \times C}$, где H и W — пространственные размеры изображения (высота и ширина), а C — количество каналов (обычно $C = 3$ для RGB-изображений). Пусть $\mathcal{K} = \{1, 2, \dots, K\}$ — множество целевых семантических классов, характерных для дорожной сцены (например, дорога, тротуар, здания, транспорт, пешеходы и т.д.).

Цель модели семантической сегментации (нейронной сети), параметризованной весами θ , заключается в поиске отображения f_θ :

$$f_\theta : \mathbb{R}^{H \times W \times C} \rightarrow \mathbb{R}^{H \times W \times K}, \quad (1)$$

которое преобразует входное изображение в тензор логитов $Z \in \mathbb{R}^{H \times W \times K}$. Для каждого пространственного положения (пикселя) с координатами (i, j) сеть предсказывает вектор $z_{i,j} \in \mathbb{R}^K$.

Вероятностное распределение принадлежности пикселя к каждому из K классов получается путем применения функции *softmax* вдоль канала классов:

$$p_{i,j}^{(k)} = \frac{\exp(z_{i,j}^{(k)})}{\sum_{c=1}^K \exp(z_{i,j}^{(c)})}, \quad (2)$$

где $p_{i,j}^{(k)}$ — предсказанная вероятность того, что пиксель (i, j) принадлежит классу k .

Итоговая предсказанная маска сегментации $\hat{Y} \in \mathcal{K}^{H \times W}$ формируется путем выбора класса с максимальной вероятностью для каждого пикселя:

$$\hat{y}_{i,j} = \arg \max_{k \in \mathcal{K}} p_{i,j}^{(k)}. \quad (3)$$

В процессе обучения модели наиболее распространенным функционалом потерь является средняя категориальная кросс-энтропия (Categorical Cross-

Entropy, CCE). Если $y_{i,j}$ — истинная метка класса для пикселя (i, j) , представленная в виде one-hot вектора (где $y_{i,j}^{(k)} = 1$, если пиксель принадлежит классу k , и 0 иначе), то функция потерь имеет вид:

$$\mathcal{L}_{CE} = -\frac{1}{H \cdot W} \sum_{i=1}^H \sum_{j=1}^W \sum_{k=1}^K y_{i,j}^{(k)} \log \left(p_{i,j}^{(k)} \right). \quad (4)$$

В отличие от задач классификации изображений в целом или детектирования объектов, сегментация требует одновременно высокой семантической точности (понимания контекста сцены) и точной локализации пространственных границ объектов. Для задач автономного вождения особенно важна стабильность качества предсказаний: модель должна корректно выделять как крупные структуры (дорожное полотно, небо), так и мелкие, слабоконтрастные, но критически важные объекты (пешеходы вдали, дорожные знаки). Это делает задачу крайне чувствительной к доменному сдвигу (domain shift) между распределением данных, на которых модель обучалась (source domain), и распределением данных в реальных условиях применения (target domain), например, при изменении погодных условий или времени суток.

2.1.2. Основные метрики: mIoU, class-wise IoU, Pixel Accuracy

Для количественной оценки качества моделей семантической сегментации используются метрики, основанные на вычислении площадей перекрытия предсказанных и истинных масок. В основе вычислений лежат базовые элементы матрицы ошибок (Confusion Matrix), рассчитываемые независимо для каждого класса k :

- TP_k (True Positives) — количество истинно-положительных пикселей (пиксели, верно отнесенные к классу k);
- FP_k (False Positives) — количество ложно-положительных пикселей (пиксели, ошибочно отнесенные к классу k);
- FN_k (False Negatives) — количество ложно-отрицательных пикселей (пиксели класса k , отнесенные моделью к другому классу);
- TN_k (True Negatives) — количество истинно-отрицательных пикселей (пиксели других классов, корректно не отнесенные к классу k).

Ключевой метрикой качества в данной работе является **mIoU** (mean Intersection over Union — среднее пересечение над объединением). Сначала вычисляется метрика **class-wise IoU** для каждого отдельного класса k , которая определяется как отношение площади пересечения предсказанной маски и ground truth маски к площади их объединения:

$$\text{IoU}_k = \frac{TP_k}{TP_k + FP_k + FN_k}. \quad (5)$$

Значение IoU_k строго лежит в диапазоне от 0 до 1. Анализ class-wise IoU позволяет проводить детальную диагностику поведения модели: например, выявлять классы с исторически низким качеством распознавания (такие как *bicycle*, *fence*, *pole* из-за их малой площади и сложной геометрии).

Интегральная метрика mIoU рассчитывается как арифметическое среднее значений IoU по всем K классам:

$$\text{mIoU} = \frac{1}{K} \sum_{k=1}^K \text{IoU}_k. \quad (6)$$

В отличие от простой пиксельной точности, mIoU является робастной метрикой в условиях сильного дисбаланса классов, который типичен для дорожных сцен (где класс «дорога» может занимать значительную часть изображения, а «светофор» — менее долей процента).

Дополнительно в работе используется базовая метрика **Pixel Accuracy (PA)** — доля корректно классифицированных пикселей по отношению к общему числу пикселей изображения:

$$\text{PA} = \frac{\sum_{k=1}^K TP_k}{\sum_{k=1}^K (TP_k + FP_k + FN_k + TN_k)} = \frac{\sum_{i=1}^H \sum_{j=1}^W \mathbb{I}(\hat{y}_{i,j} = y_{i,j})}{H \cdot W}, \quad (7)$$

где $\mathbb{I}(\cdot)$ — индикаторная функция, равная 1 при выполнении условия и 0 в противном случае. Хотя PA легко интерпретируется, она может быть обманчиво высокой при доминировании фоновых классов, поэтому используется лишь в качестве вспомогательного индикатора.

Для оценки устойчивости моделей в *adverse*-условиях (неблагоприятных условиях видимости), отдельно агрегируются и анализируются метрики по специфическим подмножествам целевого датасета (например, сценарии *fog*, *night*, *rain*, *snow* в датасете ACDC). Это позволяет явно количественно оценить степень деградации сегментации для каждого типа погодного или оптического искажения.

2.2. Архитектурные подходы

2.2.1. CNN-подходы (DeepLabV3+ как классический baseline)

Сверточные архитектуры долгое время являлись основным стандартом для задачи семантической сегментации. В работе в качестве классического подхода рассматривается **DeepLabV3+** [1], сочетающая энкодер-декодерную схему, модуль *Atrous Spatial Pyramid Pooling* и *dilated* свертки для расширения эффективного рецептивного поля без потери разрешения признаков. Такой подход позволяет одновременно учитывать контекст на нескольких масштабах и уточнять границы объектов, что особенно важно для дорожных сцен с большим числом тонких структур и малых объектов. В оригинальной статье авторы сообщают о результате **82.1% mIoU** на тестовом наборе *Cityscapes* и **89.0% mIoU** на *PASCAL VOC 2012* без дополнительного post-processing. DeepLabV3+ в данной работе используется как понятный и интерпретируемый CNN-baseline для сравнения с более современными трансформерными и foundation-подходами.

2.2.2. Transformer-подходы (SegFormer)

SegFormer [2] относится к высокоэффективным трансформерным архитектурам для семантической сегментации. Особенностью архитектуры является использование иерархического энкодера, который выдает признаки на нескольких масштабах, не требуя при этом позиционного кодирования, и легкого MLP-декодера (многослойного персептрона). Декодер объединяет разномасштабные признаки для предсказания финальной маски, что обеспечивает хороший баланс между качеством сегментации и вычислительной сложностью. В оригинальной статье наиболее сильная конфигурация *SegFormer-B5* достигает **84.0% mIoU** на тестовом наборе *Cityscapes*, а вариант *SegFormer-B4* показывает **51.8% mIoU** на *ADE20K*. В данной работе используется конфигурация *SegFormer-B2* (реализованная через библиотеку `segmentation_models_pytorch`), которая представляет современный практический подход и выступает в качестве сильного трансформерного baseline, не являющегося foundation-моделью в строгом смысле.

2.2.3. CNN-based foundation backbones (InternImage)

InternImage [3] представляет собой CNN-based foundation-модель, в которой в качестве основного оператора используется *DCNv3* — деформируемая сверт-

ка, обеспечивающая большое эффективное рецептивное поле и адаптивное пространственное агрегирование признаков. Архитектура строится как иерархический четырехстадийный бэкбон, а ее блоки сочетают свойства современных CNN и transformer-подобный дизайн, включая *Layer Normalization*, *feed-forward network* и *GELU*. Благодаря этому InternImage рассматривается как важный промежуточный вариант между классическими сверточными сетями и крупными vision foundation models.

2.2.4. *Foundation*-бэкбоны в сегментации (DINOv2)

Foundation-подходы используют предварительное обучение на масштабных и разнообразных наборах изображений без разметки (*self-supervised learning*), что существенно повышает переносимость признаков между различными доменами и задачами. **DINOv2** [4] — современная архитектура на базе *Vision Transformer*, которая благодаря обучению с дистилляцией и специальным целевым функциям формирует богатые универсальные визуальные представления. В оригинальной статье показано, что даже замороженный бэкбон DINOv2 в связке с *ViT-Adapter* достигает **60.2% mIoU** на *ADE20K*, **86.9% mIoU** на *Cityscapes* и **89.0% mIoU** на *Pascal VOC*.

В рамках исследования модель **DINOv2-Small** рассматривается как основная для проверки гипотезы о том, что предобученные универсальные признаки повышают устойчивость сегментации в условиях пониженной видимости, низкого контраста и сложных погодных условий. Для решения задачи плотного предсказания (сегментации) поверх замороженного или дообучаемого (fine-tuning) бэкбона DINOv2 применяется специально разработанный легковесный линейный декодер (**LinearDecoder**). Он преобразует одномерную последовательность патч-токенов обратно в двумерное пространственное представление и с помощью билинейной интерполяции восстанавливает признаки до исходного разрешения изображения для попиксельной классификации.

2.3. *Domain Shift: DG, UDA, FDA — термины и различия*

2.3.1. DG (Domain Generalization): обучение без target-домена

2.3.2. UDA (Unsupervised Domain Adaptation): обучение с неразмеченным target

2.3.3. FDA (Fourier Domain Adaptation): частотная техника адаптации

2.3.4. Почему в данной работе основной протокол — source-only / DG-style

2.4. *Обзор литературы и SOTA-контекст*

2.4.1. Лидерборд Cityscapes→ACDC: что показывают UDA-методы

2.4.2. Какие идеи можно перенести в DG-постановку

2.4.3. Ограничения сопоставления DG-результатов с UDA-рейтинговыми результатами

3. Данные и экспериментальный протокол

3.1. *Описание датасетов*

3.1.1. Cityscapes: структура, классы, разметка

3.1.2. ACDC: adverse-условия (fog/night/rain/snow), назначение в работе

3.2. *Протокол экспериментов*

3.2.1. Обучение на Cityscapes

3.2.2. Оценка на ACDC (без обучения на ACDC в основной линии)

3.2.3. Риски и ограничения протокола

3.3. *Метрики и критерии сравнения*

3.3.1. Overall mIoU и per-condition mIoU

3.3.2. Class-wise IoU с акцентом на трудные/слабоконтрастные классы

4. Реализация системы и базовый пайплайн

Список использованной литературы

- [1] Liang-Chieh Chen и др. “Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation”. В: *arXiv preprint arXiv:1802.02611* (2018). URL: <https://arxiv.org/abs/1802.02611>.
- [2] Enze Xie и др. “SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers”. В: *Advances in Neural Information Processing Systems* 34 (2021), с. 12077—12090. URL: https://proceedings.neurips.cc/paper_files/paper/2021/file/64f1f27bf1b4ec22924fd0acb550c235-Paper.pdf.
- [3] Wenhai Wang и др. “InternImage: Exploring Large-Scale Vision Foundation Models with Deformable Convolutions”. В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, с. 14408—14419. URL: https://openaccess.thecvf.com/content/CVPR2023/papers/Wang_InternImage_Exploring_Large-Scale_Vision_Foundation_Models_With_Deformable_Convolutions_CVPR_2023_paper.pdf.
- [4] Maxime Oquab и др. “DINOv2: Learning Robust Visual Features without Supervision”. В: *arXiv preprint arXiv:2304.07193* (2023).